EM алгоритм. Модель гауссовской смеси.

Конспект преподавателя и разбор заданий

ИППИ РАН | Байесовские методы машинного обучения | Осень 2026

Цель семинара — понять EM как алгоритм обучения модели со скрытыми переменными, реализовать гауссовскую смесь и использовать эти идеи в задаче, где один объект — целое распределение, заданное нормированным вектором из B вероятностей. Студенты должны сами определить полезное сходство распределений, сравнить модели признаков с генеративной моделью на симплексе и проверить свой выбор. В основной модели случайны и набор ненулевых координат, и распределение массы между ними. Точные нули входят в модель наблюдений и сохраняются во всех заданиях.

Материалы продолжают прошлый семинар про вариационный вывод и VAE. Используется та же ELBO, но для конечной смеси E-шаг вычисляется точно. Основной маршрут не требует нейросетей. Ноутбук содержит определения, задания на реализацию, аналитические проверки, контролируемые опыты и вопросы к интерпретации; заполненная версия сохраняет реальный запуск.

1 Проведение семинара

Предполагаются формула Байеса, ожидание, нормальная плотность, элементарное дифференцирование и NumPy. Все данные генерируются локально. Для основных заданий нужны NumPy, SciPy, Matplotlib, scikit-learn и IPython; PyTorch используется только в приложении. GPU и загрузка датасета не нужны.

Этап	Содержание и ожидаемый результат	Минуты
Модель и вывод	Скрытая метка, ELBO, вывод E/M для GMM	20
Задания 1–2	Собственная GMM, проверки и игрушечные примеры	35
Модель на симплексе	Случайный носитель, плотность на гранях, E/GEM	30
Основная задача	Реализация и сравнение методов на новых объектах	45
Обсуждение	Контрольные опыты, ограничения и интерпретация	20

Основной маршрут рассчитан на 150 минут. Для занятия на 120 минут предоставьте цикл Gaussian EM и сократите контрольные опыты, сохранив сравнение методов в основной задаче. Совместная модель VAE и кластеров предназначена для продолжения или самостоятельной работы. Сначала студенты формулируют собственную модель и план сравнения; затем преподаватель открывает предложенный вариант.

Комментарий преподавателю. В студенческой версии незаполненные функции вызывают `NotImplementedError`. Только это исключение переводит проверку в состояние «задание ещё не выполнено»; настоящие ошибки не скрываются. После заполнения нужно повторно выполнить определение функции, проверку и зависимые эксперименты. Итоговый ARI не является условием прохождения теста.

2 Гауссовская смесь и скрытые переменные

Пусть наблюдения $x_1, \dots, x_N \in \mathbb{R}^d$ независимы. Вводим скрытые метки $z_i \in \{1, \dots, K\}$:

$$p(z_i = k) = \pi_k, \qquad p(x_i \mid z_i = k) = \mathcal{N}(x_i; \mu_k, \Sigma_k), \qquad \pi_k > 0, \quad \sum_k \pi_k = 1, \quad \Sigma_k \succ 0.$$

Нормальная плотность равна

$$\mathcal{N}(x;\mu,\Sigma) = (2\pi)^{-d/2}|\Sigma|^{-1/2}\exp\Big[-\tfrac{1}{2}(x-\mu)^\top\Sigma^{-1}(x-\mu)\Big].$$

Совместная модель и маргинальная плотность имеют вид

$$p_\theta(x_i, z_i = k) = \pi_k\mathcal{N}(x_i;\mu_k,\Sigma_k), \qquad p_\theta(x_i) = \sum_k \pi_k\mathcal{N}(x_i;\mu_k,\Sigma_k).$$

Параметры $\theta = \{\pi_k,\mu_k,\Sigma_k\}_{k=1}^K$ оцениваем по наблюдаемому логарифму правдоподобия

$$\ell(\theta) = \sum_i \log\sum_k \pi_k\mathcal{N}(x_i;\mu_k,\Sigma_k).$$

Это сумма логарифмов плотностей, а не вероятностей отдельных точек. Поэтому значение ℓ может быть положительным. Логарифмы натуральные.

Если бы метки были известны, полное логарифмическое правдоподобие было бы

$$\log p_\theta(X,z) = \sum_{i,k}\mathbf{1}\{z_i = k\}[\log\pi_k + \log\mathcal{N}(x_i;\mu_k,\Sigma_k)].$$

Каждая компонента обучалась бы отдельно. EM заменяет неизвестные индикаторы их условными ожиданиями, сохраняя неопределённость назначения.

На доске. Чем отличаются π_k и $p(z_i = k \mid x_i)$? Первый вес описывает долю компоненты до наблюдения объекта; второй зависит от конкретного x_i. Перестановка всех номеров компонент не меняет плотность. Поэтому номер кластера сам по себе не имеет смысла. Число компонент также не обязано совпадать с числом мод: близкие гауссианы могут давать одну моду.

Комментарий преподавателю. В этом семинаре EM оценивает параметры точечно методом ML. Точный постериор E-шага относится к z_i при фиксированном θ. Это не байесовский постериор по параметрам смеси и не алгоритм их сэмплирования.

3 От ELBO к E- и M-шагам

Для каждого объекта введём произвольное распределение $q_i(k)$. Определим

$$\mathcal{F}(q,\theta) = \sum_{i,k} q_i(k)[\log p_\theta(x_i, z_i = k) - \log q_i(k)].$$

При соглашении $0\log 0 = 0$ и корректном покрытии носителя раскрываем KL:

$$D_{\mathrm{KL}}(q_i\|p_\theta(z_i \mid x_i)) = \sum_k q_i(k)\log q_i(k) - \sum_k q_i(k)\log p_\theta(x_i, z_i = k) + \log p_\theta(x_i),$$

$$\ell(\theta) = \mathcal{F}(q,\theta) + \sum_i D_{\mathrm{KL}}(q_i\|p_\theta(z_i \mid x_i)).$$

Неотрицательность KL даёт нижнюю границу. Параметр q нужен для её оптимизации, а не как дополнительная часть генеративной модели.

3.1 E-шаг

При текущем $\theta^{(t)}$ максимизируем границу по q. Оптимум достигается на точном постериоре:

$$r_{ik} = q_i^{(t)}(k) = \frac{\pi_k^{(t)}\mathcal{N}(x_i;\mu_k^{(t)},\Sigma_k^{(t)})}{\sum_l \pi_l^{(t)}\mathcal{N}(x_i;\mu_l^{(t)},\Sigma_l^{(t)})}.$$

Для каждого i веса неотрицательны и суммируются в единицу. Число r_{ik} называют ответственностью компоненты за объект. Жёсткое назначение $\arg\max_k r_{ik}$ удобно для рисунка, но в M-шаг передаются сами мягкие веса.

3.2 M-шаг и гарантия подъёма

При фиксированном $q^{(t)}$ энтропия не зависит от новых параметров. Поэтому максимизируем

$$Q(\theta \mid \theta^{(t)}) = \sum_{i,k} r_{ik} \log p_\theta(x_i, z_i = k).$$

При точной максимизации или хотя бы увеличении этой функции

$$\ell(\theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t)}) = \ell(\theta^{(t)}).$$

Равенство справа обеспечено E-шагом. После изменения θ зазор KL обычно снова положителен, пока не выполнен следующий E-шаг. Монотонность не означает ни глобального оптимума, ни существования конечного максимума, ни полезности получившихся кластеров.

На доске. Предложите студентам восстановить цепочку самостоятельно. Типичная ошибка — считать, что граница совпадает с правдоподобием для любых q и θ. Другая ошибка — перепутать условное ожидание логарифма совместной модели с логарифмом ожидаемого правдоподобия.

3.3 Связь с VAE

Вариационный вывод ограничивает семейство q, например нейросетевым гауссовским энкодером. Тогда точный постериор может не принадлежать этому семейству, и KL-зазор не обязан обращаться в ноль. В конечной смеси E-шаг — точное суммирование по K меткам, а не Монте-Карло и не репараметризация дискретной случайной величины. Нейросетевой M-шаг обычно также заменяется градиентными обновлениями.

4 Вывод M-шага для гауссовской смеси

Положим $N_k = \sum_i r_{ik}$. Часть Q, зависящая от весов, равна $\sum_k N_k \log \pi_k$. С множителем Лагранжа для $\sum_k \pi_k = 1$ получаем $N_k/\pi_k - \lambda = 0$, откуда

$$\pi_k^{\text{new}} = N_k / N.$$

При фиксированной ковариации производная по среднему равна $\Sigma_k^{-1} \sum_i r_{ik}(x_i - \mu_k)$, поэтому

$$\mu_k^{\text{new}} = \frac{1}{N_k} \sum_i r_{ik} x_i.$$

Теперь центрируем по *новому* среднему и обозначим $S_k = N_k^{-1} \sum_i r_{ik}(x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^\top$. Часть цели для ковариации:

$$Q_k = -\frac{N_k}{2}\left[\log|\Sigma_k| + \operatorname{tr}(\Sigma_k^{-1} S_k)\right] + \text{const}.$$

При положительно определённом S_k оптимум равен

$$\Sigma_k^{\text{new}} = S_k.$$

Если S_k вырожденна, без дополнительных ограничений внутреннего положительно определённого максимума может не быть. Деление производится на N_k, а не на $N_k - 1$: это ML-обновление, не несмещённая оценка дисперсии.

4.1 Диагональная модель и фиксированный нижний порог

В собственной реализации $\Sigma_k = \operatorname{diag}(v_{k1}, \ldots, v_{kd})$. Взвешенная покоординатная дисперсия равна

$$s_{kj}^2 = \frac{1}{N_k} \sum_i r_{ik}(x_{ij} - \mu_{kj}^{\text{new}})^2.$$

Зафиксируем $v_{kj} \geq v_{\min} > 0$. Для одной координаты цель имеет вид $-N_k[\log v + s^2/v]/2$, её производная пропорциональна $(s^2 - v)/v^2$. Следовательно, точный M-шаг в этом ограниченном семействе:

$$v_{kj}^{\text{new}} = \max\{s_{kj}^2, v_{\min}\}.$$

Такой шаг сохраняет доказательство подъёма ограниченной задачи. Операция $s^2 + \varepsilon$ отличается от $\max(s^2, v_{\min})$. В `sklearn` параметр `reg_covar` добавляет величину к диагонали; поэтому буквального совпадения двух реализаций не требуется.

4.2 Вырождение, старты и критерий остановки

Без ограничений одна компонента может стянуть ковариацию к нулю около отдельной точки, делая плотность там неограниченной. Рост обучающего правдоподобия тогда сопровождается плохой моделью данных. В семинаре используем нижний порог дисперсий, несколько стартов и проверку отложенной плотности там, где сравниваются одинаковые наблюдения.

Если $N_k < 10^{-10}$, данный запуск прекращается. Случайное восстановление пустой компоненты — возможная практическая эвристика, но оно уже не является тем точным M-шагом, для которого выведена монотонность. Истории разных запусков нельзя склеивать в одну кривую подъёма.

В коде история содержит начальную и финальную цели. Остановка происходит, когда улучшение не превосходит $\texttt{tol}\,(1 + |\ell_{\text{previous}}|)$; дополнительно установлен предел итераций. Из независимых стартов выбирается лучший по обучающей цели. Флаг достижения критерия и число итераций нужно сообщать вместе с результатом.

5 Разбор заданий 1–2 и игрушечных опытов

5.1 Стабильный E-шаг и формы массивов

Для диагональной модели

$$\log \mathcal{N}(x_i; \mu_k, \operatorname{diag} v_k) = -\frac{1}{2} \sum_j \left[\log(2\pi v_{kj}) + \frac{(x_{ij} - \mu_{kj})^2}{v_{kj}} \right].$$

Вычисляем $a_{ik} = \log \pi_k + \log \mathcal{N}(x_i; \mu_k, \operatorname{diag} v_k)$ и

$$s_i = \operatorname{logsumexp}_k(a_{ik}), \qquad r_{ik} = \exp(a_{ik} - s_i), \qquad \ell = \sum_i s_i.$$

Тождество $\operatorname{logsumexp}(a) = m + \log \sum_k e^{a_k - m}$ с $m = \max_k a_k$ объясняет устойчивость. Прямое вычисление маленьких плотностей может дать нули, а последующая нормировка — неопределённость $0/0$.

Величина	Форма массива	Смысл осей
X	(N, d)	объект, координата
μ, v	(K, d)	компонента, координата
a, r	(N, K)	объект, компонента
π, N_k	$(K,)$	компонента

На доске. Для $d = 1$, $\pi_1 = \pi_2 = 1/2$, $\mu_1 = 0$, $\mu_2 = 2$, $v_1 = v_2 = 1$ и $x = 0$ разность логарифмических оценок равна $a_1 - a_2 = 2$. Значит $r_1 = 1/(1 + e^{-2}) \approx 0.8808$. Для $x = 1$ обе ответственности равны $1/2$. Для $x = 10000$ вычисления в логарифмах остаются конечными.

5.2 Контроль M-шага

Для точек $0, 2, 8, 10$ и жёстких групп $\{0, 2\}$, $\{8, 10\}$ должны получиться веса $(1/2, 1/2)$, средние $(1, 9)$ и дисперсии $(1, 1)$. Если все точки совпали, дисперсия после ограниченного M-шага равна $v_{\min}$. Далее проверяются нормировка ответственностей, подъём цели и совпадение последнего значения истории с правдоподобием возвращённой модели. Тесты не требуют восстановления конкретной нумерации компонент.

5.3 Что обсуждать на рисунках

Первый пример состоит из трёх диагональных гауссиан. На одном рисунке показаны назначения, энтропия $-\sum_k r_{ik} \log r_{ik}$ и история цели. Энтропия выше в областях, где компоненты дают сопоставимые плотности. Это неопределённость скрытой метки при фиксированных оценённых параметрах, а не оценка неопределённости самих параметров.

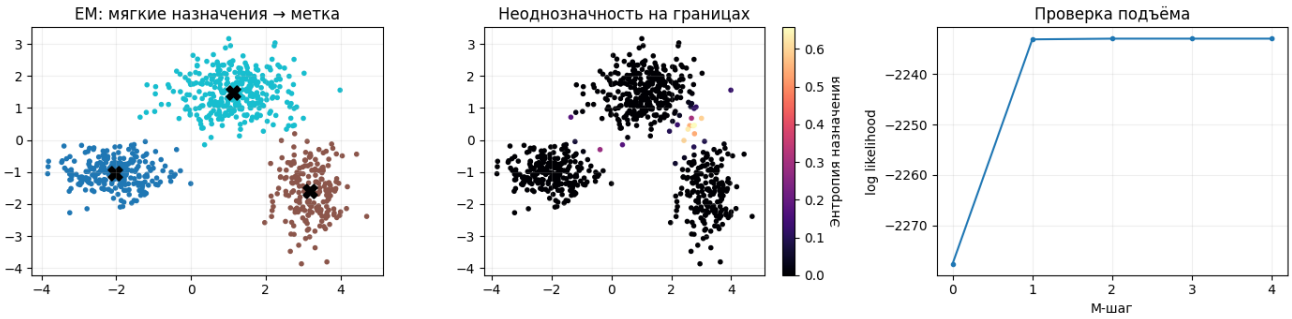


Рис. 1: Игрушечный пример из заполненного ноутбука: мягкие назначения, неоднозначность компоненты и подъём наблюдаемого логарифма правдоподобия.

В контрольном запуске наша диагональная модель и диагональная `GaussianMixture` дают средний обучающий $\log p(x) \approx -2.9772$. Это удобная проверка согласованности, а не гарантия совпадения всех стартов. Во втором примере компоненты вытянуты и повёрнуты. Для общей отложенной выборки средний $\log p(x)$ равен примерно -3.4660 у диагональной и -3.1948 у полной модели. Полная ковариация описывает наклон облаков. Здесь значения сравнимы: обе плотности определены в исходном $\mathbb{R}^2$.

5.4 Связь с K-means

При фиксированной общей ковариации $\sigma^2 I$ и равных весах

$$r_{ik} \propto \exp[-\|x_i - \mu_k\|^2/(2\sigma^2)].$$

При $\sigma \to 0$ и единственном ближайшем среднем ответственность сосредоточивается на нём. M-шаг средних превращается в обновление K-means. Это объясняет связь, но не делает произвольную GMM тождественной K-means: разные веса и ковариации меняют границы, а конечная дисперсия даёт мягкие веса.

6 Основная постановка: объектом является распределение

Даны N распределений на общей системе из B бинов или категорий. Объект i — известный вектор вероятностей

$$p_i = (p_{i1}, \ldots, p_{iB}) \in \Delta_{B-1}, \qquad \Delta_{B-1} = \left\{ p \in \mathbb{R}^B : p_b \geq 0,\ \sum_b p_b = 1 \right\}.$$

Наблюдаемая матрица P имеет форму (N, B): строка — одно распределение, столбец — общая для всех объектов категория. Допустимы произвольные точные нули, в том числе векторы $(1, 0, \dots, 0)$. Нужно объединить *целые распределения* в содержательные группы и назначать группу новому вектору p. Метку группы будем обозначать c_i; она относится к строке, а не к отдельному бину.

По умолчанию у категорий нет порядка или расстояния. Если задана числовая опора $t_1 < \cdots < t_B$, то p_i определяет дискретную меру $\sum_b p_{ib}\delta_{t_b}$. При использовании интервалов координата p_{ib} является массой интервала. Высоту плотности h_{ib} на интервале ширины Δ_b сначала переводят в массу $p_{ib} = h_{ib}\Delta_b$.

Сходство распределений зависит от задачи. Можно считать существенными положение массы, форму, ширину или набор возможных исходов. В учебном сравнении нужно явно сказать, какие различия сохраняет выбранный метод. Модель признаков и генеративная модель распределений решают эту задачу разными способами; обе требуют проверки на новых объектах.

На доске. Пусть $p = (0.5, 0, 0.5)$ и $q = (0, 1, 0)$. Какие свойства различают эти объекты? Может ли модель сгенерировать каждый из них? Что произойдёт при объединении первых двух категорий? Получатся $(0.5, 0.5)$ и $(1, 0)$: нормировка сохраняется, часть информации теряется.

Комментарий преподавателю. Дайте парам пять минут на собственное предложение. Попросите описать генерацию нового объекта и назначение кластера, а также объяснить, какой смысл имеют нулевые координаты. Среднее по номерам категорий без числовой опоры не является содержательным признаком.

7 Базовые методы: представление, PCA и GMM

В качестве эвристических ориентиров используем два представления, определённых для любого $p \in \Delta_{B-1}$:

$$x(p) = p, \qquad h(p) = (\sqrt{p_1}, \dots, \sqrt{p_B}).$$

В обоих случаях PCA обучается на training, после чего GMM обучается на сохранённых координатах. Новые объекты проходят те же фиксированные преобразования. Можно отдельно проверить GMM по исходным массам с диагональной ковариацией. Размерность PCA, регуляризация и число стартов задаются до открытия тестовых меток.

Для корней вероятностей есть геометрическое объяснение:

$$H^2(p, q) = \frac{1}{2}\sum_b (\sqrt{p_b} - \sqrt{q_b})^2, \qquad \|h(p) - h(q)\|_2 = \sqrt{2}\, H(p, q).$$

Это расстояние Хеллингера. Оно определено при нулях и одинаково при общей перестановке категорий. Все $h(p)$ лежат на единичной сфере в неотрицательном ортанте. PCA может сохранять существенные различия между такими точками, но усечение координат меняет расстояния.

На доске. Проверить $H(p, p) = 0$, симметрию, $H((1, 0, 0), (0, 1, 0)) = 1$ и $H^2((1, 0, 0), (1/4, 3/4, 0)) = 1/2$. Корни вычисляются непосредственно; входные вероятности менять не требуется.

Ограничение $\sum_b p_b = 1$ означает $\mathrm{Cov}(p)\mathbf{1} = 0$. PCA устраняет линейную избыточность и позволяет уменьшить размерность. Однако гауссиана в пространстве признаков может порождать точки, не соответствующие распределениям. Поэтому такой конвейер удобен как алгоритм кластеризации признаков. Следующий метод задаёт вероятностную модель самого наблюдаемого p.

8 Генеративная модель: случайный носитель и масса на грани

8.1 Какой объект генерирует модель

Один запуск модели должен выдать одну целую гистограмму $p = (p_1, \dots, p_B)$: все её координаты неотрицательны и в сумме равны единице. Например, $p = (1/4, 0, 3/4)$ задаёт распределение, у

которого первый бин имеет вероятность $1/4$, второй — нулевую, третий — $3/4$. В наборе данных одна такая гистограмма занимает одну строку. Модель описывает, какие *распределения* встречаются среди объектов и насколько они различаются внутри группы.

Как и в гауссовской смеси, сначала выбирается группа $c \sim \mathrm{Cat}(\pi)$. У каждой группы свой закон генерации гистограмм. Чтобы понять одну компоненту, временно зафиксируем $c = k$. В ней есть два набора параметров:

- $\rho_{kb} \in (0, 1)$ определяют, **какие бины будут активны**;
- $\alpha_{kb} > 0$ определяют, **как масса распределится между активными бинами** и насколько она будет изменяться от объекта к объекту.

Эти два выбора нужны потому, что расположение точных нулей и соотношение положительных вероятностей — разные свойства объекта.

8.2 Один объект от начала до конца: три бина

Возьмём одну компоненту с параметрами

$$B = 3, \qquad \rho_k = (0.8, 0.4, 0.6), \qquad \alpha_k = (2, 3, 4).$$

Ниже разобрана одна возможная генерация объекта.

1. Выбираем бинарную маску активности. Пусть получилась $m = (1, 0, 1)$. Значит, масса будет распределяться между бинами 1 и 3. Множество их индексов $S = \{1, 3\}$ называется *носителем*.
2. Для активных бинов выбираем положительные ненормированные веса. В этом примере пусть они равны $g_1 = 2$ и $g_3 = 6$. Закон выбора этих весов будет задан ниже. Для неактивного бина вес не нужен: его итоговая масса уже определена маской.
3. Делим активные веса на их сумму $2 + 6 = 8$:

$$p_1 = \frac{2}{8} = \frac{1}{4}, \qquad p_2 = 0, \qquad p_3 = \frac{6}{8} = \frac{3}{4}.$$

   Получена нормированная гистограмма с точным нулём во втором бине.

Маска задаёт, *где* может находиться положительная масса; нормировка весов задаёт, *сколько* её приходится на каждый активный бин. При другой генерации из той же компоненты может измениться и носитель, и соотношение положительных масс.



Рис. 2: Один объект при фиксированной компоненте: выбор активных бинов, нормировка положительных весов и полученная точка на ребре симплекса. На первом графике показаны веса после применения маски.

8.3 Как выбирается носитель и зачем исключать пустую маску

Для каждого бина независимо предлагаем индикатор $m_b \sim \text{Bernoulli}(\rho_{kb})$. Если все индикаторы оказались нулевыми, повторяем выбор *всей маски*. Это необходимо: при пустом носителе нельзя распределить единичную массу, а знаменатель в нормировке весов был бы равен нулю. В результате получаем совместное распределение исходно независимых Bernoulli-индикаторов, *условленное непустотой маски*:

$$m \mid c = k \sim \left[\prod_{b=1}^{B} \text{Bernoulli}(\rho_{kb})\right] \;\Big|\; \sum_b m_b > 0.$$

До исключения пустой маски вероятность конкретного набора индикаторов равна $\prod_b \rho_{kb}^{m_b}(1-\rho_{kb})^{1-m_b}$. Пустая маска имеет вероятность $\prod_b(1-\rho_{kb})$. Поэтому вероятность принять предложение и вероятность выбранной маски равны

$$Z_k = 1 - \prod_b (1-\rho_{kb}), \qquad q_k(m) = \frac{\prod_b \rho_{kb}^{m_b}(1-\rho_{kb})^{1-m_b}}{Z_k}, \quad m \neq 0.$$

Деление на Z_k перенормирует вероятности оставшихся вариантов, чтобы они снова суммировались в единицу.

В нашем примере пустая маска имеет вероятность $0.2 \cdot 0.6 \cdot 0.4 = 0.048$, поэтому $Z_k = 0.952 = 119/125$. Маска $(1,0,1)$ до условия непустоты имеет вероятность $0.8 \cdot 0.6 \cdot 0.6 = 0.288$, а после него

$$q_k(1,0,1) = \frac{0.288}{0.952} = \frac{36}{119} \approx 0.3025.$$

Все семь допустимых масок можно выписать явно:

Маска	Где находится полученная гистограмма	Вероятность
$(1,0,0)$	Вершина $(1,0,0)$	$24/119$
$(0,1,0)$	Вершина $(0,1,0)$	$4/119$
$(0,0,1)$	Вершина $(0,0,1)$	$9/119$
$(1,1,0)$	Открытое ребро $p_3 = 0$	$16/119$
$(1,0,1)$	Открытое ребро $p_2 = 0$	$36/119$
$(0,1,1)$	Открытое ребро $p_1 = 0$	$6/119$
$(1,1,1)$	Внутренность треугольника	$24/119$

Три бина дают треугольник: одна активная координата задаёт вершину, две — ребро, три — внутренность. Носитель выбирает одну из этих частей. При большем B та же идея задаёт грани разных размерностей.

Важно, что ρ_{kb} — вероятность активности *в предложении*. После исключения пустой маски

$$\Pr(m_b = 1 \mid c = k) = \frac{\rho_{kb}}{Z_k}.$$

Действительно, событие $m_b = 1$ уже гарантирует непустоту. В примере второй бин активен с вероятностью $0.4/0.952 \approx 0.4202$. Индикаторы после условия непустоты связаны между собой. Параметр ρ_{kb} также не задаёт величину p_b: он отвечает за выбор активного бина, а его положительная масса определяется следующим шагом.

8.4 Как выбираются положительные массы и что означает параметр альфа

Для каждого активного $b \in S$ независимо выбираем

$$g_b \mid S, c = k \sim \mathrm{Gamma}(\alpha_{kb}, 1).$$

Используется параметризация «форма, интенсивность»: при $a > 0$ плотность $\mathrm{Gamma}(a, 1)$ равна

$$h(g) = \frac{g^{a-1}e^{-g}}{\Gamma(a)}, \qquad g > 0.$$

Её среднее и дисперсия равны a. Все выбранные веса положительны. Нормировка

$$p_b = \frac{g_b}{\sum_{j \in S} g_j} \quad (b \in S), \qquad p_b = 0 \quad (b \notin S)$$

сохраняет точные нули и обеспечивает $\sum_b p_b = 1$. Общая интенсивность, равная единице, удобна: закон нормированных весов зависит только от параметров формы α_{kb}.

Условно на фиксированном носителе нормированные веса имеют распределение Дирихле:

$$p_S \mid S, c = k \sim \mathrm{Dirichlet}((\alpha_{kb})_{b \in S}), \qquad A_{kS} = \sum_{b \in S} \alpha_{kb}.$$

Его параметры удобно читать через условные средние и дисперсии. Для $b \in S$ положим $u_b = \alpha_{kb}/A_{kS}$. Тогда

$$\mathbb{E}[p_b \mid S, c = k] = u_b, \qquad \mathrm{Var}(p_b \mid S, c = k) = \frac{u_b(1 - u_b)}{A_{kS} + 1}.$$

Отношения параметров задают среднее распределение массы на выбранном носителе, а их сумма задаёт концентрацию около этого среднего. Если умножить все α_{kb} на одно положительное число, условные средние сохранятся; увеличение множителя уменьшит разброс.

Для $S = \{1, 3\}$ в примере используются только параметры $(2, 4)$:

$$\mathbb{E}[p \mid S = \{1, 3\}, c = k] = (1/3, 0, 2/3).$$

Полученный ранее вектор $(1/4, 0, 3/4)$ — одна реализация около этого среднего. Параметр $\alpha_{k2} = 3$ в условное распределение на этом ребре не входит. Если активна только одна координата, её масса всегда равна единице: при таком носителе делить массу между бинами уже не нужно.

Безусловный средний профиль компоненты усредняет также выбор носителя:

$$\mathbb{E}[p_b \mid c = k] = \sum_{S:\, b \in S} q_k(S) \frac{\alpha_{kb}}{A_{kS}}.$$

Здесь $q_k(S)$ означает вероятность маски с активным набором S. Поэтому нормировка α_k по всем бинам вообще не обязана совпадать со средним наблюдаемым профилем. Его можно оценить усреднением сгенерированных из компоненты гистограмм.

8.5 Почему нормировка гамма-весов даёт Дирихле

Зафиксируем компоненту и носитель S размера $s \geq 2$. В этом выводе сократим обозначения: $a_b = \alpha_{kb}$ и $A = \sum_{b \in S} a_b$. Плотность независимых гамма-весов равна

$$h(g_S) = \frac{e^{-\sum_{b \in S} g_b}}{\prod_{b \in S} \Gamma(a_b)} \prod_{b \in S} g_b^{a_b - 1}.$$

Перейдём от весов к их сумме $\tau = \sum_{b \in S} g_b$ и нормированным координатам $p_b = g_b / \tau$. Свободными являются $s - 1$ координат p; последняя равна единице минус их сумма. Обратное преобразование $g_b = \tau p_b$ имеет якобиан τ^{s-1}. Подстановка и сбор степеней τ дают совместную плотность

$$h(\tau, p_S) = \underbrace{\frac{\tau^{A-1} e^{-\tau}}{\Gamma(A)}}_{\text{плотность Gamma}(A,1)} \underbrace{\frac{\Gamma(A)}{\prod_{b \in S} \Gamma(a_b)} \prod_{b \in S} p_b^{a_b - 1}}_{\text{плотность Dirichlet}(a_S)}.$$

Первый множитель интегрируется по $\tau > 0$ в единицу. Остаётся распределение Дирихле для нормированного вектора. Этот вывод одновременно объясняет его нормирующую константу и показывает, что вспомогательные гамма-веса можно аналитически исключить из likelihood.

При целых $a_b \geq 1$ условная плотность на грани является нормированным многочленом по активным вероятностям. При $a_b = 1$ для всех $b \in S$ она постоянна и равна $(s-1)!$. Например, на ребре это плотность 1 на интервале, а во внутренности треугольника — плотность 2 на области $p_1 > 0$, $p_2 > 0$, $p_1 + p_2 < 1$ площадью $1/2$ в координатах (p_1, p_2).

8.6 Likelihood: вероятность выбрать грань и плотность внутри неё

Для наблюдаемого p носитель уже известен:

$$S(p) = \{b : p_b > 0\}, \qquad m_b(p) = \mathbf{1}\{p_b > 0\}.$$

Сначала модель должна выбрать именно этот носитель, затем выдать соответствующее распределение положительной массы. Поэтому вклад одной компоненты имеет два множителя:

$$\boxed{f_k(p) = q_k(S(p))\, d_{k,S(p)}(p_{S(p)})},$$

где $q_k(S)$ — вероятность носителя, а $d_{k,S}$ — условная плотность Дирихле на нём. При $|S| \geq 2$

$$d_{k,S}(p_S) = \frac{\Gamma(A_{kS})}{\prod_{b \in S} \Gamma(\alpha_{kb})} \prod_{b \in S} p_b^{\alpha_{kb} - 1}.$$

Вернёмся к $p = (1/4, 0, 3/4)$ и параметрам примера. На ребре $S = \{1, 3\}$ достаточно одной координаты $u = p_1$, поскольку $p_3 = 1 - u$. Имеем $u \sim \mathrm{Beta}(2, 4)$ и

$$d_{k,\{1,3\}}(u) = 20u(1-u)^3, \qquad d_{k,\{1,3\}}(1/4) = \frac{135}{64} = 2.109375.$$

Умножая на вероятность выбрать это ребро, получаем

$$f_k(1/4, 0, 3/4) = \frac{36}{119} \frac{135}{64} = \frac{1215}{1904} \approx 0.63813.$$

Это *плотность по координате ребра*, а не вероятность отдельной точки. Например, вероятность попасть на ребро $p_2 = 0$ и одновременно получить $p_1 \in [0.25, 0.26]$ равна

$$\frac{36}{119} \int_{0.25}^{0.26} 20u(1-u)^3 \, du \approx 0.006379.$$

Вероятность всего открытого ребра равна 36/119, поскольку условная плотность интегрируется в единицу. Как обычно для непрерывного закона, вероятность одной фиксированной внутренней точки ребра равна нулю.

Для вершины $p = (0, 1, 0)$ ситуация проще: маска $(0, 1, 0)$ уже однозначно задаёт весь вектор. Поэтому здесь есть настоящая точечная вероятность

$$\Pr(p = (0, 1, 0) \mid c = k) = q_k(0, 1, 0) = \frac{0.2 \cdot 0.4 \cdot 0.4}{0.952} = \frac{4}{119}.$$

Она не зависит от α: при единственном активном бине его масса всегда равна 1. Для записи общей формулы на такой грани полагаем $d_{k,S} = 1$.

8.7 Как формально объединить внутренность, рёбра и вершины

В примере понадобились три типа вычислений: сумма вероятностей вершин, одномерный интеграл вдоль ребра и двумерный интеграл внутри треугольника. Единая мера нужна, чтобы кратко записать все три операции вместе. Она фиксирует правила интегрирования на каждой части симплекса.

Для непустого $S \subseteq \{1, \dots, B\}$ определим открытую грань

$$F_S = \{p \in \Delta_{B-1} : p_b > 0 \text{ для } b \in S,\ p_b = 0 \text{ для } b \notin S\}.$$

Каждая гистограмма принадлежит ровно одной такой грани. Грани попарно не пересекаются: вершины рассматриваются отдельно от открытых рёбер, а рёбра — отдельно от внутренности. На F_S используем обычную меру λ_S в $|S|-1$ свободных координатах симплекса, исключая, например, координату с наибольшим индексом. Для вершины λ_S — единичный атом. Зафиксируем общую для всех компонент меру

$$\mu = \sum_{\varnothing \neq S \subseteq \{1,\dots,B\}} \lambda_S.$$

Именно относительно неё $f_k(p)$ является плотностью. Проверка нормировки теперь буквально повторяет алгоритм генерации:

$$\int_{\Delta_{B-1}} f_k(p)\, d\mu(p) = \sum_{S \neq \varnothing} q_k(S) \underbrace{\int_{F_S} d_{k,S}(p_S)\, d\lambda_S(p)}_{=1} = \sum_{S \neq \varnothing} q_k(S) = 1.$$

Так одна вероятностная модель учитывает и точные нули, и непрерывную вариативность положительных масс. Все $2^B - 1$ граней используют общие векторы параметров ρ_k, α_k. Для вычисления плотности конкретного объекта нужна только его наблюдаемая грань; перебирать все носители не требуется. Одна такая компонента называется *распределением Дирихле со случайным носителем* (Dirichlet composition distribution; Tang et al., 2022).

8.8 Как из этой модели получается кластеризация

Возвращаем выбор компоненты $c \sim \mathrm{Cat}(\pi)$. Для каждой компоненты рассчитываем $f_k(p)$ по той же формуле; маргинальная плотность объекта и вероятность его кластера равны

$$f_\theta(p) = \sum_{k=1}^{K} \pi_k f_k(p), \qquad \Pr(c = k \mid p) = \frac{\pi_k f_k(p)}{\sum_l \pi_l f_l(p)}.$$

Это та же формула Байеса, что и для гауссовской смеси. Компоненты могут различаться типичными носителями, распределением массы на одном носителе или обоими свойствами.

Для численного примера добавим вторую компоненту и равные веса смеси:

$$\pi_1 = \pi_2 = 1/2, \quad \rho_1 = (0.8, 0.4, 0.6),\ \alpha_1 = (2, 3, 4), \quad \rho_2 = (0.4, 0.8, 0.6),\ \alpha_2 = (4, 3, 2).$$

Для того же $p = (1/4, 0, 3/4)$ первая компонента выбирает носитель $\{1, 3\}$ в шесть раз чаще второй: $q_1 = 36/119$, $q_2 = 6/119$. На этом носителе условные плотности в наблюдаемой точке равны $d_1 = 135/64$ и $d_2 = 15/64$; их отношение равно девяти. Итак,

$$\frac{\pi_1 f_1(p)}{\pi_2 f_2(p)} = 6 \cdot 9 = 54, \qquad \Pr(c = 1 \mid p) = \frac{54}{55} \approx 0.9818.$$

В пользу первой компоненты говорят и отсутствие массы во втором бине, и соотношение положительных масс $1 : 3$.

При обучении наблюдаемы p_i и его маска $m_i = \mathbf{1}\{p_i > 0\}$. Скрыт номер c_i. Гамма-веса — вспомогательные переменные генератора; они уже исключены при переходе к плотности Дирихле. Поэтому E-шаг вычисляет ответственности по K компонентам, а M-шаг оценивает π, ρ и α по этим мягким назначениям.

На доске. Если $p_2 = 0$, входит ли α_{k2} в плотность этого объекта? В условную часть Дирихле он не входит. Входит ли ρ_{k2}? Да: через вероятность отсутствия второго бина и нормировку Z_k. Объект сообщает, что бин неактивен; его положительную массу при активности в этом наблюдении мы не видели.

8.9 Логарифм плотности для реализации

После раздельного разбора двух множителей их логарифмы складываются:

$$\log f_k(p) = \underbrace{\sum_b [m_b \log \rho_{kb} + (1 - m_b) \log(1 - \rho_{kb})] - \log Z_k}_{\text{выбор наблюдаемого носителя}}$$
$$\underbrace{+ \log \Gamma(A_{kS}) - \sum_{b \in S} \log \Gamma(\alpha_{kb}) + \sum_{b \in S} (\alpha_{kb} - 1) \log p_b}_{\text{распределение массы на этом носителе}}, \qquad A_{kS} = \sum_{b \in S} \alpha_{kb}.$$

При $|S| = 1$ вторая строка равна нулю: гамма-функции сокращаются, а единственный логарифм массы равен $\log 1 = 0$. Логарифмы p_b берутся только на активных координатах. Во временном массиве можно оставить нули на неактивных местах и вызвать `np.log(P, out=..., where=P>0)`. Для $\log \Gamma$ используется `gammaln`. Это две части, которые студенты реализуют как `support_logpmf` и `face_dirichlet_logpdf`.

Комментарий преподавателю. Перед переходом к EM попросите студента объяснить генератор словами и указать роль каждой величины. ρ задаёт выбор активных бинов, α — закон положительных масс при выбранном носителе, π — частоты компонент среди объектов. Маска восстанавливается из наблюдаемой гистограммы; скрытой меткой для E-шага остаётся кластер.

9 EM для смеси на симплексе

Наблюдаемая цель

$$\ell(\theta) = \sum_i \log \sum_{k=1}^{K} \pi_k f_k(p_i).$$

Здесь скрыта только метка компоненты c_i. Ранее выведенное разложение через ELBO остаётся верным после замены гауссовской плотности на f_k. Ответственности:

$$a_{ik} = \log \pi_k + \log f_k(p_i), \quad s_i = \operatorname{logsumexp}_k(a_{ik}), \quad r_{ik} = \exp(a_{ik} - s_i).$$

Нормировка происходит по компонентам; $\ell = \sum_i s_i$. Вес компоненты обновляется как прежде: $\pi_k = N_k / N$.

9.1 Взвешенная задача M-шага

Для одной компоненты обозначим $w_i = r_{ik}/N_k$, $f_b = \sum_i w_i m_{ib}$ и $L_b = \sum_{i:b\in S_i} w_i \log p_{ib}$. Параметры носителя и условной массы входят в цель раздельно. Положим $\eta_b = \log(\rho_b/(1-\rho_b))$, $C(\eta) = \sum_b \log(1+e^{\eta_b})$, тогда $Z = 1 - e^{-C}$. Нормированная цель для носителя:

$$Q_{\text{mask}}/N_k = \sum_b f_b \eta_b - C(\eta) - \log(1 - e^{-C(\eta)}).$$

Из $\partial C/\partial \eta_b = \rho_b$ получаем

$$\frac{\partial (Q_{\text{mask}}/N_k)}{\partial \eta_b} = f_b - \frac{\rho_b}{Z}.$$

Таким образом, обновление $\rho_b = f_b$ в общем случае не является M-шагом: необходимо учитывать условие непустого носителя.

Для условной массы цель равна

$$Q_{\text{face}}/N_k = \sum_i w_i \log \Gamma\left(\sum_b m_{ib}\alpha_b\right) - \sum_b f_b \log\Gamma(\alpha_b) + \sum_b L_b(\alpha_b - 1).$$

Пусть ψ — дигамма-функция, а $A_i = \sum_b m_{ib}\alpha_b$. Производные:

$$\frac{\partial (Q_{\text{face}}/N_k)}{\partial \alpha_b} = \sum_i w_i m_{ib}\psi(A_i) - f_b\psi(\alpha_b) + L_b,$$

$$\frac{\partial (Q_{\text{face}}/N_k)}{\partial \log \alpha_b} = \alpha_b \left[\sum_i w_i m_{ib}\psi(A_i) - f_b\psi(\alpha_b) + L_b\right].$$

У объекта в вершине вклад в эту производную равен нулю: его масса уже определена носителем. Он по-прежнему участвует в оценивании π и ρ.

9.2 Численный M-шаг и обобщённый EM

В ноутбуке численный оптимизатор M-шага предоставлен, а студенты реализуют логарифмы частей плотности и E-шаг. Функция `numerical_face_m_step` использует приведённые градиенты и L-BFGS-B. Для воспроизводимости фиксируется компактное семейство

$$-8 \le \eta_{kb} \le 8, \qquad 0.05 \le \alpha_{kb} \le 500.$$

Это ограничения параметров модели; наблюдаемые векторы не меняются. В частности, нижняя граница α не является заменой нулевых масс. Ограничение концентрации препятствует стягиванию компоненты к единичному наблюдению. Качество и попадание параметров на границы стоит обсуждать так же, как регуляризацию ковариации у GMM.

Точного глобального решения численной подзадачи не требуется. Предложенные параметры принимаются, если соответствующая взвешенная цель Q не уменьшилась; иначе сохраняются старые параметры. Такой M-шаг является *обобщённым EM* и сохраняет цепочку подъёма ELBO. Контролировать нужно реальную цель, а не только флаг успеха оптимизатора. Несколько стартов полезны, поскольку вся задача смеси остаётся невыпуклой. Из запусков выбирается лучший по обучающему правдоподобию.

10 Задание 3: модель на гранях и её проверки

1. Реализовать `support_logpmf(M, rho)` для вероятностей носителей и `face_dirichlet_logpdf(P, alpha)` для условных масс. Их сумма даёт матрицу $\log f_k(p_i)$ формы (N, K).

2. Написать устойчивый `face_e_step`. Использовать предоставленный цикл `fit_face_mixture` с численным M-шагом и несколькими инициализациями. История включает начальную и финальную цели.
3. Проверить вершины, точки на рёбрах и внутренние точки на одном наборе из трёх категорий. Сопоставить условную плотность на ребре с $\mathrm{Beta}(\alpha_1, \alpha_2)$.
4. На маленьком примере сравнить аналитические градиенты M-шага с центральными конечными разностями. Проверить нормировку ответственностей, конечность цели и её подъём с учётом точности вычислений.
5. Сгенерировать игрушечную смесь с $B = 3$, нарисовать симплекс, разбиение и историю цели. Затем назначить группы новым распределениям.

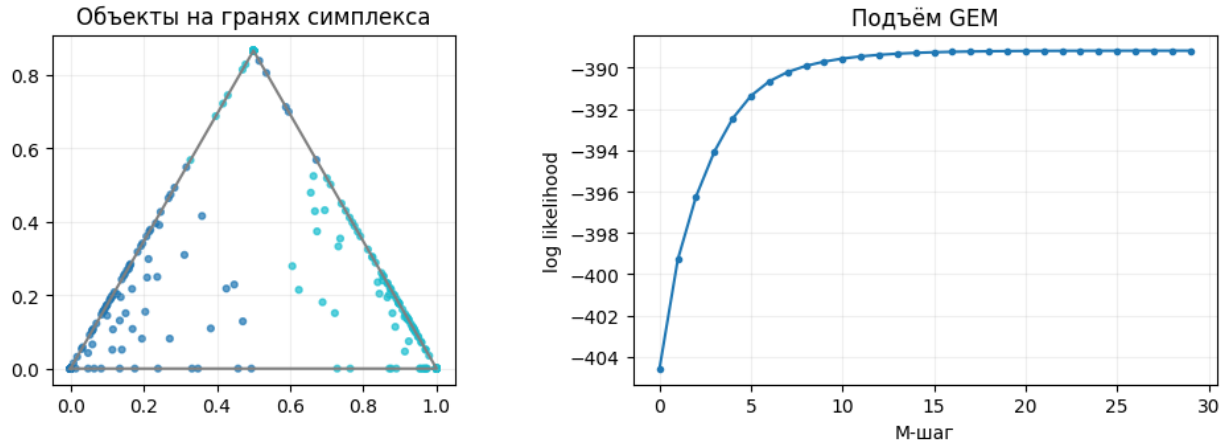


Рис. 3: Игрушечная смесь на трёх категориях: нулевые массы, мягкие назначения и подъём цели EM. Точки на границах входят в тот же likelihood, что и внутренние точки.

Минимальные проверки не требуют высокого ARI или определённой нумерации компонент. На вершинах должна исчезать зависимость от α. Общая перестановка координат наблюдений, ρ и α не должна менять плотность. Проверка только на внутренних точках недостаточна. В реализации генератора активные гамма-веса нормируются непосредственно, а не превращаются в счётчики наблюдений.

11 Учебные данные и честный протокол

Основной эксперимент содержит $N = 720$ распределений на $B = 64$ категориях, $K = 4$ известно из условия. Для наглядности задана общая числовая опора $t_b \in [-3.5, 3.5]$. Используются четыре профиля

$$
\begin{aligned}
v_1(t) &= \exp[-\tfrac{1}{2}(t/0.9)^4], \\
v_2(t) &= \exp[-((t^2-1)/0.65)^2], \\
v_3(t) &= \exp[-\tfrac{1}{2}((t+0.4)/0.85)^2] + 0.4\exp[-\tfrac{1}{2}((t-1.5)/0.6)^2], \\
v_4(t) &= \exp[-\tfrac{1}{2}((t-0.4)/0.85)^2] + 0.4\exp[-\tfrac{1}{2}((t+1.5)/0.6)^2].
\end{aligned}
$$

Нормируем их по категориям: $u_{kb} = v_k(t_b)/\sum_j v_k(t_j)$. Параметры генератора:

$$
\alpha_{kb} = 0.12 + 100u_{kb}, \qquad \rho_{kb} = 0.62 + 0.25\frac{u_{kb}}{\max_j u_{kj}}.
$$

Метки сбалансированы и перемешаны. Далее для каждой строки выбираются маска и гамма-веса по описанной генеративной модели. Координаты неактивных категорий в точности равны нулю. Формы u_k помогают задать параметры; сами наблюдения случайны и не обязаны быть гладкими.

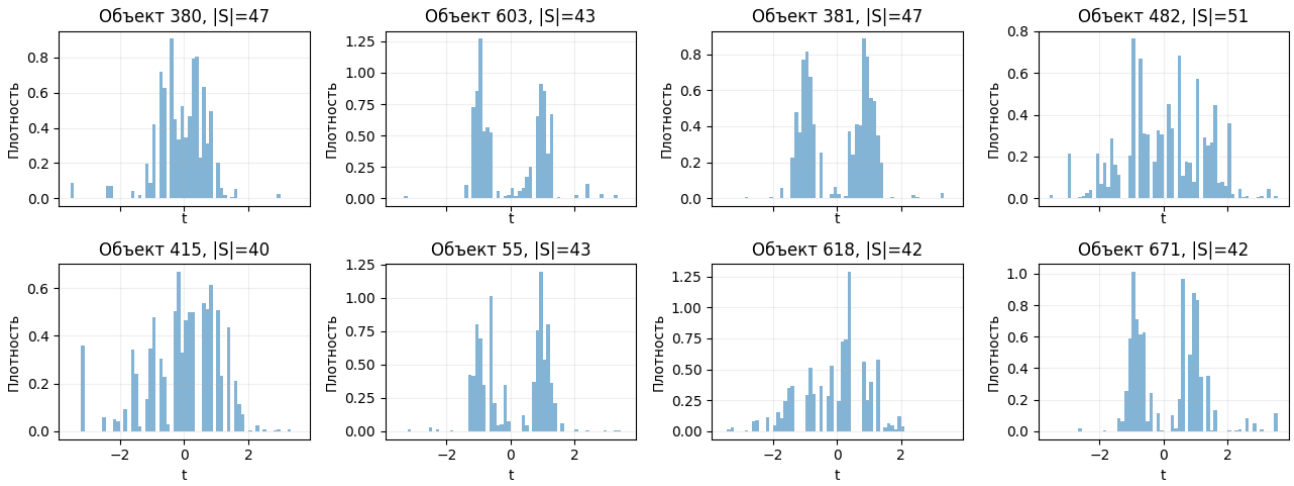


Рис. 4: Наблюдаемые векторы вероятностей из учебного генератора. Одна строка — один объект кластеризации; нулевые массы сохраняются.

Разделяются целые строки: 480 обучающих и 240 тестовых объектов. Состояние генератора данных — 2026, разбиения — 42. В сохранённом наборе доля точных нулей равна 30.0825%. Все преобразования и модели обучаются только на training. К числу обучаемых преобразований относятся PCA и энкодер. Тестовые объекты используются для назначения кластеров и заключительного аудита. Метки открываются после фиксации методов и параметров. Программный доступ к ним — учебное сокрытие ответа, а не защита от чтения генератора.

Комментарий преподавателю. Основной генератор соответствует проверяемой модели. Это позволяет проверить восстановление при выполненных предположениях, но создаёт преимущество этой модели. Для проверки переносимости студенты должны дополнительно изменить вариативность или зависимость носителей. Победа на этом эксперименте не является общим ранжированием методов.

12 Задание 4: сравнить эвристику и генеративную модель

До запуска предложите студентам письменно сформулировать гипотезу: какое отличие объектов должен обнаружить метод и почему выбранная модель это отличие сохраняет? В минимальный план сравнения входят

1. корни масс, PCA с 8 координатами и собственная диагональная GMM из задания 2: реализовать `fit_distribution_clustering`;
2. смесь Дирихле со случайным носителем, обученная EM;
3. дополнительный ориентир: PCA исходных масс и полная GMM или кластеризация только по маскам;
4. собственная модификация и опыт, показывающий её пользу или ограничение.

Для генеративного метода нужно показать параметры ρ_k, α_k, примеры сгенерированных объектов, мягкие назначения и историю цели. В частности, график $\alpha_k / \sum_b \alpha_{kb}$ не равен общему математическому ожиданию $p \mid c = k$: нормировка массы зависит от случайного носителя. Среднее распределение удобно оценить генерацией новых объектов модели.

Для признаковых методов пояснить, сколько координат сохранено и почему гауссовские компоненты имеют выбранные ковариации. Отдельно сравнить диагональную и полную ковариацию в одной фиксированной проекции. Число стартов, размерность PCA и регуляризация влияют на результат одновременно с выбором представления.

12.1 Что измерять

После фиксации вариантов открыть истинные метки и вычислить ARI и NMI на тесте. Обе метрики инвариантны к перестановке номеров кластеров. При разных стартах полезно сравнить назначения одних и тех же новых объектов. Такая устойчивость измеряет чувствительность к инициализации, но сама по себе не подтверждает содержательность групп.

Нужно также показать несколько объектов каждого найденного кластера, доли нулевых масс и распределение энтропии ответственностей. Большая уверенность модели может сопровождаться неверными назначениями при неподходящих предположениях.

Логарифмы плотностей GMM в разных PCA-пространствах и смеси на симплексе определены относительно разных мер и напрямую несопоставимы. Общие ARI/NMI оценивают разбиения. Отложенное правдоподобие смеси на симплексе пригодно для сравнения её вариантов при фиксированных B и мере μ; train/test должны содержать те же типы наблюдений.

12.2 Контроль: изменение условной формы масс

Сохраним носители и метки, но преобразуем каждый объект:

$$T(p)_b = \frac{p_b^2}{\sum_j p_j^2}.$$

Точные нули остаются нулями. Преобразование обратимо: $T^{-1}(q)_b = \sqrt{q_b}/\sum_j \sqrt{q_j}$. Следовательно, информация о первоначальном объекте не теряется, но его геометрия и условное распределение масс меняются. На каждой грани преобразованное распределение в общем случае уже не является распределением Дирихле.

Преобразовать training и test, заново обучить преобразования и модели на training, после чего повторить аудит. Сравнить изменение качества PCA по массам, PCA по корням масс и смеси на случайном носителе. Поскольку носители не меняются, этот опыт отделяет их наблюдение от пригодности семейства условных масс. Параметры не перенастраиваются по результатам тестового аудита.

12.3 Дополнительные контроли

1. Одинаковая перестановка категорий у всех объектов. Плотности и назначения при соответствующей перестановке параметров должны сохраниться.
2. Проверка вершин и редких носителей на отдельных новых объектах: конечные плотности, нормированные ответственности, генерация похожих объектов.
3. Изменение зависимости индикаторов: исключать целые блоки соседних категорий совместно. Условная независимость предложений маски тогда нарушается; исследовать, какие методы сохраняют качество.
4. Объединение соседних бинов и переобучение моделей на суммах масс для $B = 64, 16, 8, 4, 2$. Это отдельный опыт с потерей информации.

Для укрупнения сохраняется нормировка. Хеллингер не возрастает: по Коши–Буняковскому $\sqrt{(\sum_b p_b)(\sum_b q_b)} \geq \sum_b \sqrt{p_b q_b}$ на каждом объединённом бине, а $H^2 = 1 - \sum_b \sqrt{p_b q_b}$. Это не означает монотонного изменения ARI. Если разные распределения после объединения совпали, никакая модель по укрупнённым данным не восстановит утраченные различия без дополнительной информации.

Комментарий преподавателю. После объединения категорий могут измениться и механизм активности, и условная модель масс. Переобучение того же семейства проверяет сразу потерю информации и пригодность модели на новой сетке. В отличие от него степенной контроль обратим и не теряет информации.

12.4 Ожидаемый содержательный разбор

Генеративная модель отделяет вероятность отсутствия категории от вариативности её массы при присутствии. Признаковый метод может оказаться успешным, если главное различие видно в выбранной проекции. Он также может объединить объекты с разными носителями или потерять существенную малую компоненту при усечении PCA. С другой стороны, неверное предположение о механизме носителя или условной форме масс может повредить генеративной модели. Вывод должен объяснять наблюдаемый результат через эти свойства, а не объявлять один подход универсально лучшим.

Итог работы — таблица метрик, несколько рисунков и короткое объяснение: что моделировалось; какие предположения использовались; как проверялась реализация; какие различия сохранились в кластерах; где метод ошибается. Конкретный ARI не является условием зачёта.

12.5 Разбор сохранённого запуска

Метод	Test ARI	Test NMI
PCA масс + полная GMM	0.7320	0.7691
PCA корней масс + свой диагональный EM	0.6084	0.7733
Смесь DCD, EM	0.9175	0.9172
Кластеризация только по носителям	0.0122	0.0612
W_1, медоиды, приложение	0.6257	0.7343
Совместная DCD–VAE, приложение	0.5885	0.7076

В выбранном запуске DCD остановка достигнута после шести обновлений; средний отложенный логарифм плотности равен 190.6306. Это плотность относительно фиксированной смешанной меры μ, а не вероятность отдельного вектора. Её положительный логарифм допустим. Число стартов DCD равно трём. Значения не являются порогами оценивания; версии библиотек и численная оптимизация могут немного менять результат.

Модель DCD хорошо работает на соответствующем ей генераторе. Маски по отдельности почти не восстанавливают семейства: существенна именно условная структура масс. При этом признаки по исходным массам дают полезное разбиение, а более сложный VAE в данном запуске уступает обоим методам. Малый набор и более трудная совместная оптимизация не дают оснований ожидать автоматического преимущества нейросетевой модели. Архитектура и этапы обучения фиксируются до тестового аудита.

Повторные запуски также полезны. Для состояний 11, 22 и 33 ARI между отложенными назначениями равны соответственно 0.6159, 1.0000 и 0.6159 для пар $(11, 22)$, $(11, 33)$ и $(22, 33)$. Даже три инициализации не устраняют локальные решения: устойчивость одних запусков не является доказательством глобального оптимума.

После $p_b \mapsto p_b^2 / \sum_j p_j^2$	Test ARI	Test NMI
PCA масс + полная GMM	0.2914	0.4278
PCA корней масс + свой диагональный EM	0.6688	0.7269
Смесь DCD, EM	0.8956	0.9017

Обратимое преобразование существенно меняет качество метода по массам, хотя исходная информация сохранена. DCD здесь сохраняет высокое качество, но это результат данного опыта с нарушенным семейством, а не гарантия устойчивости к любому изменению. По двум таблицам нельзя выбирать гиперпараметры: это заключительный аудит заранее заданных конвейеров.

13 Приложение: числовая опора и расстояние Васерштейна

Если дана общая упорядоченная опора $t_1 < \cdots < t_B$, то для дискретных мер

$$W_1(p, q) = \sum_{b=1}^{B-1} \left| \sum_{j \le b} (p_j - q_j) \right| (t_{b+1} - t_b).$$

Формула учитывает стоимость переноса массы. Расстояние Хеллингера между разными вершинами симплекса одинаково, а W_1 увеличивается при удалении соответствующих точек опоры. Поэтому W_1 отвечает на другой вопрос о сходстве. Для категорий без заданной геометрии номера столбцов не определяют стоимость переноса.

Студенты могут сравнить метод медоидов с этой метрикой. Назначение выполняется ближайшему обучающему медоиду; внутри группы медоидом становится объект с наименьшей суммой расстояний до её членов. Используют несколько стартов. Полная матрица расстояний требует памяти $O(N^2)$. Новые объекты не участвуют в переоценке медоидов. Проверки: точечные массы и сопоставление с `scipy.stats.wasserstein_distance`.

14 Приложение: выбор числа компонент

В основной задаче K дано. В самостоятельном продолжении предлагается выбирать его по внутренней валидации, интерпретации и устойчивости. Для смеси на симплексе отложенная цель должна вычисляться относительно той же фиксированной меры μ. Тестовые метки для выбора K не используются.

Для GMM можно рассмотреть BIC в одном фиксированном пространстве:

$$\mathrm{BIC} = -2\ell(\widehat{\theta}) + m \log N, \qquad m = (K-1) + Kd + K\frac{d(d+1)}{2}$$

для полной ковариации. Меньше — лучше. При изменении K обучающая PCA-проекция остаётся той же. Смеси имеют особые точки и перестановочную неидентифицируемость, поэтому регулярное асимптотическое обоснование BIC здесь не даёт универсальной гарантии. Число компонент плотности также не обязано совпадать с числом содержательных групп.

15 Приложение: VAE с совместной моделью кластеров

Нейросетевая модель сохраняет тот же наблюдаемый объект и тот же механизм точных нулей. Генеративная схема:

$$c \sim \mathrm{Cat}(\pi), \qquad z \mid c = k \sim \mathcal{N}(\nu_k, \mathrm{diag}(v_k)), \qquad p \mid z \sim \mathrm{DCD}(\rho_\theta(z), \alpha_\theta(z)).$$

Декодер выдаёт параметры непустой маски и положительных гамма-весов. Чтобы сгенерировать распределение, нужно выбрать c, затем z, маску, гамма-веса и нормировать активные веса. Все части модели обучаются вместе. Смесь в латентном prior является частью модели кластеризации.

Энкодер получает корни масс $\sqrt{p}$ и наблюдаемую маску $m = \mathbf{1}\{p > 0\}$:

$$q_\phi(z \mid p, m) = \mathcal{N}(\mu_\phi(p, m), \mathrm{diag}(e^{s_\phi(p,m)})).$$

После аналитического суммирования по c prior равен

$$p(z) = \sum_k \pi_k \mathcal{N}(z; \nu_k, \mathrm{diag}(v_k)).$$

ELBO одного объекта:

$$\mathcal{L}(p) = \mathbb{E}_{q_\phi(z|p,m)}[\log f_\theta(p \mid z) + \log p(z) - \log q_\phi(z \mid p, m)].$$

Здесь f_θ — уже выведенная плотность DCD относительно μ. Логарифм смеси в prior вычисляется через `logsumexp`; условная плотность DCD при фиксированном z задаётся одним семейством. Ожидание оценивается репараметризацией $z = \mu_\phi + e^{s_\phi/2} \odot \varepsilon$, $\varepsilon \sim \mathcal{N}(0, I)$. Дискретные c и m в этом расчёте не сэмплируются: c просуммирована, а m наблюдается. Коэффициент при всех трёх слагаемых равен единице.

В заполненном ноутбуке $J = 4$. Энкодер имеет слои $2B \to 96 \to 64$ с tanh, затем головы среднего и логарифмической дисперсии; декодер — $4 \to 64 \to 96$ с tanh и головы параметров маски и масс. Параметр массы задаётся как $0.05 + \mathrm{softplus}(a)$ с верхней границей 500; логиты маски ограничиваются от -8 до 8. Эти операции относятся к параметрам, а не к наблюдаемым вероятностям. Вычисления в float64 сохраняют малые положительные массы наряду с точными нулями.

Обучение начинается со 100 эпох с обычным нормальным prior. Затем GMM по средним энкодера на training инициализирует смесь в prior; к диагональной дисперсии добавляется средняя дисперсия энкодера. После инициализации все параметры энкодера, декодера и prior совместно обучаются 350 эпох по выписанному ELBO. Эта инициализация не использует истинные метки. Батч содержит 160 объектов, для обучения берутся два сэмпла на объект; Adam использует шаг 0.002 на первом этапе и 0.001 на совместном. Для финальных ответственностей используется $S = 100$. Ограничение нормы градиента равно 20. Критерии инициализации и число эпох фиксируются до тестового аудита.

15.1 Назначение кластера и проверка модели

Для данного латентного z posterior компоненты вычисляется точно:

$$\gamma_k(z) = p(c = k \mid z) = \frac{\pi_k \mathcal{N}(z; \nu_k, \mathrm{diag}(v_k))}{\sum_l \pi_l \mathcal{N}(z; \nu_l, \mathrm{diag}(v_l))}.$$

Приближённое назначение наблюдаемого объекта:

$$\widehat{r}_k(p) = \frac{1}{S} \sum_{s=1}^{S} \gamma_k(z^{(s)}), \qquad z^{(s)} \sim q_\phi(z \mid p, m).$$

Это вариационная оценка $p(c = k \mid p)$; точность зависит и от энкодера, и от числа сэмплов. Оценка по одному среднему μ_ϕ не учитывает неопределённость q_ϕ. Номера компонент имеют тот же перестановочный смысл, что и у EM.

Веса нейросети остаются точечными оценками. Средний ELBO оценивает качество модели наблюдений, ARI/NMI — соответствие разбиения учебным меткам. Малая ошибка восстановления не гарантирует полезных кластеров. Стохастическая история обучения не обязана быть монотонной. Архитектура, число эпох и критерий выбора по внутренней валидации фиксируются до открытия тестовых меток.

Комментарий преподавателю. Попросите студентов нарисовать генеративный граф и указать, что наблюдается, что выводится и что суммируется точно. Затем сопоставить формулы $\widehat{r}_k(p)$ и E-шага обычной смеси. Это связывает семинар с предыдущим занятием, сохраняя единую модель наблюдений.

16 Проверки, типичные ошибки и оценивание

Симптом	Проверка и объяснение
NaN на нулевых массах	Логарифмы вычислять только при $p_b > 0$; не умножать уже вычисленный $\log 0$ на нулевой индикатор.
Вершина зависит от α	На одноточечном носителе условная плотность равна 1; проверить гамма-часть и $\log 1 = 0$.
Плотность носителей не нормирована	Проверить исключение пустой маски и константу Z_k. Не подставлять частоты активности вместо ρ_k.
Цель EM убывает	Проверить softmax по компонентам, новые параметры, взвешенную цель M-шага и приём численного обновления.
Разные номера правильных групп	Перестановка компонент не меняет модель; сравнивать разбиения инвариантной метрикой.
Слишком хороший тест	Проверить обучение PCA и энкодера только на training и отсутствие настройки по тестовым меткам.
Плохое обобщение	Проверить предположения о носителе, условных массах, границы параметров и различие training/test.

Предлагаемая шкала на 10 баллов: Gaussian E/M и объяснение — 3; плотность на гранях, её проверки и E-шаг — 3; честное сравнение с эвристическими методами — 2; собственный контроль и интерпретация — 2. VAE и дополнительные эксперименты могут давать дополнительные баллы. Уровень ARI в шкалу не входит.

Итоговые вопросы: почему E-шаг делает ELBO точной; когда численный M-шаг сохраняет подъём; чем отличаются скрытая метка и наблюдаемая маска; зачем нужна нормировка непустого носителя; какая мера используется для плотности в вершине; что моделирует PCA/GMM и что моделирует DCD; какие свойства теряются при укрупнении; какие предположения проверяет синтетический эксперимент; как вводится кластерная переменная в VAE.

Источники и границы материала

1. A. P. Dempster, N. M. Laird, D. B. Rubin (1977). *Maximum Likelihood from Incomplete Data via the EM Algorithm*. https://doi.org/10.1111/j.2517-6161.1977.tb01600.x.
2. R. M. Neal, G. E. Hinton (1998). *A View of the EM Algorithm that Justifies Incremental, Sparse, and Other Variants*. Авторский PDF: https://www.cs.toronto.edu/~hinton/absps/emk.pdf.
3. M.-L. Tang, Q. Wu, S. Yang, G.-L. Tian (2022). *Dirichlet composition distribution for compositional data with zero components: An application to fluorescence in situ hybridization (FISH) detection of chromosome*. Biometrical Journal, 64(4), 714–732. https://doi.org/10.1002/bimj.202000334. Открытый полный текст: https://bura.brunel.ac.uk/bitstream/2438/23914/1/FullText.pdf.
4. D. P. Kingma, M. Welling. *Auto-Encoding Variational Bayes*. https://arxiv.org/abs/1312.6114.
5. scikit-learn. *Gaussian mixture models*: https://scikit-learn.org/stable/modules/mixture.html.
6. SciPy. *wasserstein_distance*: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wasserstein_distance.html.

Случайный носитель и гамма-представление DCD соответствуют модели Tang et al. Смешивание DCD-компонент, учебный генератор, численные сравнения и нейросетевое продолжение разработаны для этого семинара; они не воспроизводят эксперименты перечисленных статей. EM и его вариационное объяснение соответствуют классической постановке. Ограничения параметров и численная оптимизация оговорены отдельно.