Конспект семинара

ИППИ РАН

Variational inference, ELBO, VAE

По статье D. P. Kingma и M. Welling

Auto-Encoding Variational Bayes

arXiv:1312.6114v11

Вариационный вывод рассматривается на примере вероятностной модели с непрерывной скрытой переменной. Из тождества для апостериорной KL-дивергенции выводятся ELBO, стохастические оценки её градиента и алгоритм AEVB. Гауссовский вариационный автоэнкодер служит конкретной реализацией этой схемы.

Отдельно разобран переход от наблюдений x к парам (x, y): извлечение признаков, совместное моделирование и условная генеративная модель для классификации или регрессии. Различаются распределения, используемые при обучении и при предсказании.

Вычислительная часть сопровождается англоязычным блокнотом `variational_inference_elbo_vae.ipynb`. В нём приведены точные проверки формул и небольшие воспроизводимые эксперименты. Результаты этих экспериментов не являются воспроизведением численных результатов исходной статьи.

Основной текст: модель, вывод и алгоритм.
Разделы 7–9 и приложения: расширения, проверки и порядок демонстраций.

Содержание

1 Модель и обозначения **2**
- 1.1 Что именно рассматривается в исходной статье . . . 2
- 1.2 Генеративная модель и задача обучения . . . 3

2 Вариационный вывод и ELBO **3**
- 2.1 KL-дивергенция и условия корректности . . . 3
- 2.2 Вывод основного тождества . . . 4
- 2.3 Вывод через неравенство Йенсена . . . 4
- 2.4 Реконструкционный член и KL к априорному распределению . . . 5

3 Амортизация и обучение параметров **5**
- 3.1 Локальный вывод и общий энкодер . . . 5
- 3.2 Связь с EM и отличие от точного максимального правдоподобия . . . 6
- 3.3 ML, MAP и масштабирование критерия . . . 6

4 Репараметризация, SGVB и AEVB **6**
- 4.1 Производная ожидания с зависящим от параметров законом . . . 6
- 4.2 Переход к шуму с фиксированным распределением . . . 7
- 4.3 Гауссовский случай . . . 7
- 4.4 Две оценки SGVB . . . 8
- 4.5 Мини-батчи и полный алгоритм . . . 8

5 Гауссовский VAE и функции потерь **9**
- 5.1 Энкодер и декодер как параметризации распределений . . . 9
- 5.2 Полный вывод гауссовской KL . . . 9
- 5.3 Бернуллиевский декодер и бинарная кросс-энтропия . . . 10
- 5.4 Гауссовский декодер и квадратичная ошибка . . . 10
- 5.5 Редукции в коде и вес KL . . . 11
- 5.6 Реконструкция, генерация и коллапс апостериорного распределения . . . 11

6 Переход к классификации и регрессии **12**
- 6.1 Соответствие двух постановок . . . 12
- 6.2 Первый вариант: признаки VAE и отдельный предиктор . . . 12
- 6.3 Второй вариант: совместная модель пары . . . 13
- 6.4 Третий вариант: условный VAE . . . 13
- 6.5 Условный гауссовский prior и вычисление его KL . . . 14
- 6.6 Классификация: категориальный декодер . . . 14
- 6.7 Регрессия: условная смесь нормальных распределений . . . 15

7 Частично размеченные данные: дополнительная модель **16**

8 Точные примеры для проверки вычислений **17**
- 8.1 Скалярная линейно-гауссовская модель . . . 17
- 8.2 Ненулевой разрыв диагонального семейства . . . 18
- 8.3 Дисперсия скор-градиента и pathwise-градиента . . . 19

9 Вычислительная часть семинара **19**
- 9.1 Протокол и связь с исходной работой . . . 19
- 9.2 Проверки до обучения сети . . . 20
- 9.3 VAE на бинарных цифрах . . . 22
- 9.4 Логарифм правдоподобия и importance sampling . . . 23
- 9.5 Классификация: два различных эксперимента . . . 24
- 9.6 Регрессия с двумя возможными ответами . . . 26
- 9.7 Что именно проверено . . . 28

A Вариационный вывод для глобальных параметров **28**

B Порядок изложения у доски **29**

Соответствие формулам основной статьи **30**

Литература и источники **30**

1. Модель и обозначения

1.1. Что именно рассматривается в исходной статье

Основной источник — предоставленная версия статьи *Auto-Encoding Variational Bayes* [1]. В её основной части скрытые переменные z имеют вариационное апостериорное распределение, а параметры генеративной модели θ оцениваются точечно по критерию приближённого максимального правдоподобия или максимума апостериорной плотности. Полностью байесовский вариант для θ вынесен авторами в приложение F. Эти две постановки не следует смешивать.

Тождество для ELBO не требует ни нейронной сети, ни нормального распределения, ни диагональной ковариации. Однако рассматриваемая реализация SGVB использует непрерывную скрытую переменную и дифференцируемую репараметризацию. Поэтому общую вариационную схему можно объяснить через VAE, но нельзя объявлять конкретное гауссовское семейство VAE представлением всех моделей без потери общности.

В тексте сохранены основные обозначения статьи. Там, где один символ исходной статьи обозначает разные объекты, различие указано явно. Все логарифмы натуральные; единица логарифмических величин — нат.

Обозначение	Значение
$X = \{x^{(i)}\}_{i=1}^{N}$	Выборка наблюдений в обозначениях статьи; N — её объём, i — номер наблюдения.
$x \in \mathcal{X}$, D	Наблюдаемая величина и число её координат. Далее $\mathcal{X} = \mathbb{R}^D$ или $\{0,1\}^D$; d нумерует координаты x.
$z \in \mathbb{R}^J$	Непрерывная скрытая величина; J — её размерность, j — номер координаты. Каждому $x^{(i)}$ соответствует своё $z^{(i)}$.
θ, ϕ	Общие для всей выборки параметры генеративной модели и вариационного распределения соответственно.
$p_\theta(z)$, $p_\theta(x \mid z)$	Априорное распределение скрытой величины и условное распределение наблюдения; последнее называется вероятностным декодером.
$p_\theta(z \mid x)$, $q_\phi(z \mid x)$	Точное апостериорное распределение и его вариационное приближение; q_ϕ называется вероятностным энкодером.
$\mu^{(i)}, \sigma^{(i)} \in \mathbb{R}^J$	Среднее и покоординатные стандартные отклонения $q_\phi(z \mid x^{(i)})$. Все $\sigma_j^{(i)} > 0$.
$s^{(i)} = \log(\sigma^{(i)})^2$	Вектор логарифмов дисперсий. Квадрат и логарифм применяются покоординатно.
I_J, $\odot$, $\mathrm{diag}(v)$	Единичная матрица размера J; покоординатное произведение; диагональная матрица с вектором v на диагонали.
$\epsilon \sim p(\epsilon)$	Вспомогательный шум, закон которого не зависит от оптимизируемых параметров.
L, M, l	Число выборок скрытой величины на наблюдение, размер мини-батча и номер выборки шума.
$\mathcal{L}$, $\widetilde{\mathcal{L}}$	Точная вариационная нижняя граница и её случайная оценка. Это разные объекты.

Запись $\sigma^2 I$ в формуле (9) статьи понимается как диагональная ковариация, составленная из вектора дисперсий. Здесь используется однозначная запись $\mathrm{diag}(\sigma^2)$. В приложении C.1 статьи буква y обозначает вероятности на выходе бернуллиевского декодера. В этом конспекте они обозначены через $\rho_\theta(z)$, чтобы впоследствии освободить y для целевой переменной. В начале раздела 5 статьи слова encoder и decoder в одной фразе переставлены; далее используются определения раздела 2.1 и рисунка 1: энкодер — q_ϕ, декодер — $p_\theta(x \mid z)$.

1.2. Генеративная модель и задача обучения

Для одного наблюдения предполагается двухэтапный механизм: сначала z генерируется из $p_\theta(z)$, затем x — из $p_\theta(x \mid z)$. По правилу умножения условных плотностей совместный закон равен

$$p_\theta(x, z) = p_\theta(z) p_\theta(x \mid z). \tag{1.1}$$

Здесь и далее слово «плотность» включает функцию вероятностей дискретной величины. Интегрирование скрытой переменной и формула Байеса дают соответственно

$$p_\theta(x) = \int_{\mathbb{R}^J} p_\theta(z) p_\theta(x \mid z)\, \mathrm{d}z, \tag{1.2}$$

$$p_\theta(z \mid x) = \frac{p_\theta(z) p_\theta(x \mid z)}{p_\theta(x)}. \tag{1.3}$$

Апостериорная плотность определена для наблюдений с $0 < p_\theta(x) < \infty$. Если x непрерывен, $p_\theta(x)$ не является вероятностью события «наблюдение в точности равно x»; такая вероятность обычно нулевая. Плотность может превышать единицу.

Предположим, что пары $(x^{(i)}, z^{(i)})$ независимы при фиксированном θ и имеют одну и ту же модель. Тогда совместный закон выборки факторизуется по i. Интегрируя каждое $z^{(i)}$ отдельно и логарифмируя произведение, получаем

$$p_\theta(X) = \prod_{i=1}^{N} p_\theta(x^{(i)}), \qquad \ell(\theta; X) := \log p_\theta(X) = \sum_{i=1}^{N} \log p_\theta(x^{(i)}). \tag{1.4}$$

Максимизация ℓ по θ есть метод максимального правдоподобия. Если задана плотность априорного распределения параметров $p(\theta)$, то максимум апостериорной плотности ищется максимизацией $\ell(\theta; X) + \log p(\theta)$: нормировочная константа апостериорной плотности не зависит от θ.

В нелинейной модели интеграл (1.2) часто нельзя вычислить аналитически или с приемлемой стоимостью. Это одновременно затрудняет нормировку (1.3) и обучение по (1.4). Утверждение относится к выбранной модели, а не ко всем моделям со скрытыми переменными: линейно-гауссовский пример в разделе 8 допускает точное решение.

2. Вариационный вывод и ELBO

2.1. KL-дивергенция и условия корректности

Пусть q и p — нормированные плотности относительно одной меры. Для скрытого непрерывного z этой мерой будет мера Лебега. Определим

$$D_{\mathrm{KL}}(q \| p) = \int q(z) \log \frac{q(z)}{p(z)}\, \mathrm{d}z. \tag{2.1}$$

На множестве $q = 0$ вклад считается нулевым. Если q приписывает положительную массу множеству, на котором $p = 0$, то $D_{\mathrm{KL}}(q \| p) = +\infty$. Для конечных вычислений далее предполагается $q \ll p$, то есть абсолютная непрерывность q относительно p, и конечность всех отдельно записанных ожиданий.

Утверждение 2.1. $D_{\mathrm{KL}}(q \| p) \geq 0$. *Равенство имеет место тогда и только тогда, когда $q = p$ почти всюду.*

Доказательство. Для $t > 0$ справедливо $\log t \leq t - 1$: функция $t - 1 - \log t$ имеет минимум нуль при $t = 1$. На множестве $A = \{z : q(z) > 0\}$ подставим $t = p(z)/q(z)$ и проинтегрируем с весом q:

$$\int_A q(z) \log \frac{p(z)}{q(z)}\, \mathrm{d}z \leq \int_A [p(z) - q(z)]\, \mathrm{d}z = \int_A p(z)\, \mathrm{d}z - 1 \leq 0. \tag{2.2}$$

Меняя знак, получаем неотрицательность. Равенство требует $p/q = 1$ q-почти всюду и отсутствия массы p вне A, то есть совпадения распределений. Случай бесконечной KL не противоречит неравенству. □

KL-дивергенция не является метрикой: в частности, её аргументы нельзя переставлять. В вариационном выводе статьи минимизируется направление $q\|p$, где ожидание берётся по доступному приближению q.

2.2. Вывод основного тождества

Зафиксируем θ и наблюдение x с $0 < p_\theta(x) < \infty$. Возьмём нормированную плотность $q_\phi(z \mid x) \ll p_\theta(z \mid x)$. В этом подразделе сокращённо пишем $q(z) = q_\phi(z \mid x)$. Подстановка (1.3) в определение KL даёт

$$\begin{aligned} D_{\mathrm{KL}}(q\|p_\theta(\cdot \mid x)) &= \int q(z)\big[\log q(z) - \log p_\theta(x, z) + \log p_\theta(x)\big]\,\mathrm{d}z \\ &= \log p_\theta(x) - \int q(z)\big[\log p_\theta(x, z) - \log q(z)\big]\,\mathrm{d}z. \end{aligned} \tag{2.3}$$

Во второй строке использована нормировка $\int q(z)\,\mathrm{d}z = 1$. Определим последний интеграл:

$$\mathcal{L}(\theta, \phi; x) := \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x, z) - \log q_\phi(z \mid x)]. \tag{2.4}$$

Тогда (2.3) принимает вид формулы (1) статьи:

$$\boxed{\log p_\theta(x) = \mathcal{L}(\theta, \phi; x) + D_{\mathrm{KL}}(q_\phi(z \mid x)\|p_\theta(z \mid x)).} \tag{2.5}$$

Из неотрицательности KL следует

$$\mathcal{L}(\theta, \phi; x) \le \log p_\theta(x), \qquad \mathcal{L}(\theta, \phi; x) = \log p_\theta(x) \iff q_\phi(z \mid x) = p_\theta(z \mid x) \text{ п.в.} \tag{2.6}$$

ELBO означает *evidence lower bound*: нижняя граница логарифма маргинальной плотности наблюдения. Для вариационного вывода при фиксированном θ нормирующая константа $\log p_\theta(x)$ не зависит от ϕ. Поэтому из (2.5) непосредственно следует эквивалентность максимизации ELBO и минимизации апостериорной KL по ϕ.

В пространстве всех допустимых плотностей точное апостериорное распределение достигает равенства. Поэтому при выполнении условий конечности имеет место вариационное представление

$$\log p_\theta(x) = \sup_q \mathbb{E}_q[\log p_\theta(x, z) - \log q(z)]. \tag{2.7}$$

Супремум по ограниченному семейству может быть строго меньше правой части и не обязан достигаться. Переход от функциональной оптимизации по q к параметризации q_ϕ и есть выбор вариационного семейства.

2.3. Вывод через неравенство Йенсена

Если q положительна всюду, где $p_\theta(x, z) > 0$, то маргинальную плотность можно записать как ожидание:

$$p_\theta(x) = \int q(z)\frac{p_\theta(x, z)}{q(z)}\,\mathrm{d}z = \mathbb{E}_q\frac{p_\theta(x, z)}{q(z)}. \tag{2.8}$$

По вогнутости логарифма,

$$\log p_\theta(x) = \log \mathbb{E}_q\frac{p_\theta(x, z)}{q(z)} \ge \mathbb{E}_q \log\frac{p_\theta(x, z)}{q(z)} = \mathcal{L}(\theta, \phi; x). \tag{2.9}$$

Для точного равенства в (2.8) требуется покрытие носителя совместной плотности предложением q. Это условие сильнее, чем условие $q \ll p_\theta(\cdot \mid x)$, достаточное для конечной апостериорной KL. Если q не покрывает весь носитель, то

$$\log p_\theta(x) \geq \log \int_{\{q>0\}} p_\theta(x,z)\,\mathrm{d}z = \log \mathbb{E}_q \frac{p_\theta(x,z)}{q(z)} \geq \mathcal{L}(\theta,\phi;x). \tag{2.10}$$

Таким образом, сама нижняя граница сохраняется; нельзя лишь без проверки заменять полный интеграл ожиданием в (2.8).

2.4. Реконструкционный член и KL к априорному распределению

Разложим совместную плотность по (1.1) внутри (2.4):

$$\begin{aligned}\mathcal{L}(\theta,\phi;x) &= \mathbb{E}_q \log p_\theta(x \mid z) + \mathbb{E}_q[\log p_\theta(z) - \log q_\phi(z \mid x)] \\ &= \mathbb{E}_{q_\phi(z|x)} \log p_\theta(x \mid z) - D_{\mathrm{KL}}(q_\phi(z \mid x) \| p_\theta(z)).\end{aligned} \tag{2.11}$$

Это формула (3) статьи. Первый член оценивает, насколько наблюдение согласуется с декодером при скрытых состояниях из $q_\phi(z \mid x)$. Второй препятствует произвольному отклонению вариационного распределения от априорного. Его часто интерпретируют как регуляризатор, но коэффициент перед ним здесь не выбирается отдельно: единица получается из вывода ELBO.

В (2.5) KL сравнивает q_ϕ с *апостериорным* распределением и равна разрыву границы. В (2.11) KL сравнивает q_ϕ с *априорным* распределением и входит внутрь вычисляемого критерия. Максимизация ELBO не означает, что каждое $q_\phi(z \mid x)$ должно совпасть с априорным: реконструкционный член обычно этому противодействует.

3. Амортизация и обучение параметров

3.1. Локальный вывод и общий энкодер

В обычной вариационной схеме для каждого наблюдения можно независимо оптимизировать локальные параметры λ_i плотности $q_{\lambda_i}(z)$. В AEVB используется отображение $x \mapsto \lambda_\phi(x)$ с общими параметрами ϕ. Один проход по энкодеру выдаёт параметры распределения для нового x; отдельная итерационная оптимизация λ_i при каждом обращении уже не требуется. Именно эта замена амортизирует стоимость вывода [1, разделы 2.1–2.3].

Чтобы разделить причины неточности, зафиксируем θ и обозначим через $\mathcal{Q}$ выбранное семейство локальных плотностей. Пусть $\mathcal{L}_i(q)$ означает (2.4) для $x^{(i)}$. Введём три числа

$$\begin{aligned}A &:= \sum_i \log p_\theta(x^{(i)}), \qquad B := \sum_i \sup_{q\in\mathcal{Q}} \mathcal{L}_i(q), \\ C &:= \sup_\phi \sum_i \mathcal{L}_i(q_\phi(\cdot \mid x^{(i)})).\end{aligned} \tag{3.1}$$

Предполагается, что каждый выход энкодера принадлежит $\mathcal{Q}$ и все супремумы конечны. Тогда $A \geq B \geq C$. Для реально найденного ϕ имеем точное разложение

$$A - \sum_i \mathcal{L}_i(q_\phi) = \underbrace{A-B}_{\text{ограничение семейства}} + \underbrace{B-C}_{\text{амортизационный разрыв}} + \underbrace{C - \sum_i \mathcal{L}_i(q_\phi)}_{\text{неполная оптимизация}}. \tag{3.2}$$

Каждое слагаемое неотрицательно. Равенство получается добавлением и вычитанием B и C, а не предположением об успешности обучения. Это разложение относится к фиксированному θ; при совместном обучении сама апостериорная цель меняется.

3.2. Связь с EM и отличие от точного максимального правдоподобия

Обозначим совокупность локальных распределений через q. В точном EM на шаге t выбирается $q_t(z) = p_{\theta_t}(z \mid X)$, поэтому граница касается логарифма правдоподобия: $\mathcal{L}(\theta_t, q_t; X) = \ell(\theta_t; X)$. Если последующий шаг увеличивает границу при фиксированном q_t, то

$$\ell(\theta_{t+1}; X) \geq \mathcal{L}(\theta_{t+1}, q_t; X) \geq \mathcal{L}(\theta_t, q_t; X) = \ell(\theta_t; X). \tag{3.3}$$

Первое неравенство — ELBO, второе — условие шага оптимизации, последнее равенство — точный E-шаг. При приближённом апостериорном распределении последнего равенства может не быть. Следовательно, рост вариационной границы сам по себе не доказывает монотонного роста точного правдоподобия. AEVB делает совместные стохастические шаги по θ и ϕ, а не требует решения точного E-шага.

При независимых параметризациях p_θ и q_ϕ и допустимости дифференцирования под интегралом из (2.4) следует

$$\nabla_\theta \mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)} \nabla_\theta \log p_\theta(x, z). \tag{3.4}$$

Для точного правдоподобия, напротив,

$$\begin{aligned} \nabla_\theta \log p_\theta(x) &= \frac{1}{p_\theta(x)} \int \nabla_\theta p_\theta(x, z) \, \mathrm{d}z \\ &= \int p_\theta(z \mid x) \nabla_\theta \log p_\theta(x, z) \, \mathrm{d}z. \end{aligned} \tag{3.5}$$

Во второй строке использованы $\nabla p = p \nabla \log p$ и формула Байеса. Ожидания (3.4) и (3.5) вообще говоря различны. Несмещённая оценка градиента ELBO не является автоматически несмещённой оценкой градиента точного логарифма правдоподобия.

3.3. ML, MAP и масштабирование критерия

Суммарная ELBO определяется суммой $\mathcal{L}(\theta, \phi; X) = \sum_i \mathcal{L}(\theta, \phi; x^{(i)})$. Она следует из (1.4) и локальных границ. Приближённые ML и MAP используют соответственно

$$\max_{\theta, \phi} \sum_i \mathcal{L}(\theta, \phi; x^{(i)}), \qquad \max_{\theta, \phi} \left\{ \sum_i \mathcal{L}(\theta, \phi; x^{(i)}) + \log p(\theta) \right\}. \tag{3.6}$$

Например, для P скалярных параметров, собранных в вектор $\theta \in \mathbb{R}^P$, и априорного $\mathcal{N}(0, \tau_\theta^2 I_P)$ логарифм плотности равен константе минус $\|\theta\|^2 / (2\tau_\theta^2)$. Поэтому при минимизации отрицательной *средней* ELBO соответствующее MAP-слагаемое равно $\|\theta\|^2 / (2N\tau_\theta^2)$. Множитель N нельзя потерять, изменяя сумму на среднее только в части критерия. В блокноте дополнительного априорного штрафа на параметры нет.

4. Репараметризация, SGVB и AEVB

4.1. Производная ожидания с зависящим от параметров законом

Пусть $F(\phi) = \int q_\phi(z) f_\phi(z) \, \mathrm{d}z$. Предположим, что носитель не зависит от ϕ, производные существуют почти всюду, а модуль производной подынтегрального выражения локально ограничен некоторой интегрируемой функцией. Это достаточные условия переноса производной под интеграл. По правилу произведения

$$\begin{aligned} \nabla_\phi F &= \int \left[q_\phi(z) \nabla_\phi f_\phi(z) + f_\phi(z) \nabla_\phi q_\phi(z) \right] \mathrm{d}z \\ &= \mathbb{E}_{q_\phi} \left[\nabla_\phi f_\phi(z) + f_\phi(z) \nabla_\phi \log q_\phi(z) \right]. \end{aligned} \tag{4.1}$$

Последняя запись использует $\nabla q = q\nabla \log q$ там, где $q > 0$. Это оценивание через скор-функцию. Если f не зависит явно от ϕ, первое слагаемое исчезает. Для общего интегранда ELBO такая зависимость есть из-за $-\log q_\phi$, и её нельзя забывать.

Из нормировки q_ϕ при тех же условиях следует

$$\mathbb{E}_{q_\phi} \nabla_\phi \log q_\phi(z) = \int \nabla_\phi q_\phi(z)\, \mathrm{d}z = \nabla_\phi 1 = 0. \tag{4.2}$$

Следовательно, из множителя $f_\phi(z)$ в скор-слагаемом можно вычесть число b или функцию наблюдения x, не зависящую от данного z, без изменения математического ожидания. При автоматическом дифференцировании такого оценивателя необходимо отдельно реализовать нужный оцениватель, а не случайно дифференцировать выбранный baseline как дополнительный целевой член.

Прямое усреднение выборочных скор-градиентов может иметь большую дисперсию. Формула (4.1) корректна; проблема здесь вычислительная, а не логическая. Точный пример сравнения дисперсий приведён в разделе 8.3.

4.2. Переход к шуму с фиксированным распределением

Предположим, что найдены распределение $p(\epsilon)$, независимое от ϕ, и отображение $g_\phi(\epsilon, x)$, такие что при $\epsilon \sim p(\epsilon)$ случайная величина

$$z = g_\phi(\epsilon, x) \tag{4.3}$$

имеет в точности закон $q_\phi(z \mid x)$. Иными словами, q_ϕ является образом меры $p(\epsilon)$ при g_ϕ. По определению распределения образа для любой интегрируемой функции f_ϕ,

$$\mathbb{E}_{q_\phi(z|x)} f_\phi(z) = \mathbb{E}_{p(\epsilon)} f_\phi(g_\phi(\epsilon, x)). \tag{4.4}$$

Обратимость g_ϕ для этого равенства не нужна. Если отображение обратимо и гладко по шуму, его можно также получить из обычной формулы замены переменных с якобианом. Сама репараметризация не является приближением; приближение возникает лишь при оценке ожидания конечным числом выборок.

Предположим дополнительно, что полная производная композиции в (4.4) допускает интегрируемую доминанту. Обозначим через $\partial_\phi g_\phi$ якобиан g_ϕ по параметрам. Правило цепочки даёт

$$\nabla_\phi \mathbb{E}_q f_\phi(z) = \mathbb{E}_{p(\epsilon)} \left[\nabla_\phi f_\phi(z)\big|_{z=g_\phi} + (\partial_\phi g_\phi)^{\mathsf{T}} \nabla_z f_\phi(g_\phi) \right]. \tag{4.5}$$

Первая производная внутри скобок берётся при фиксированном z, вторая учитывает зависимость выборки от ϕ. Это градиент по траектории, или pathwise gradient. Шум фиксируется при дифференцировании, но выборка z не отсоединяется от параметров.

Дифференцируемости почти всюду самой по себе недостаточно для (4.5): необходимо обосновать обмен производной и ожидания. Для произвольной дискретной скрытой переменной наивное пороговое отображение непрерывного шума обычно имеет нулевую производную почти всюду и скачки, поэтому такая аргументация не даёт нужного градиента. Это ограничение репараметризованного алгоритма, а не ограничения тождества ELBO.

4.3. Гауссовский случай

Для диагонального нормального распределения положим

$$\epsilon \sim \mathcal{N}(0, I_J), \qquad z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon. \tag{4.6}$$

Аффинный образ нормального вектора нормален. Его среднее равно $\mu_\phi(x)$, так как $\mathbb{E}\epsilon = 0$. Ковариация равна

$$\operatorname{diag}(\sigma_\phi)\, I_J\, \operatorname{diag}(\sigma_\phi) = \operatorname{diag}(\sigma_\phi^2), \tag{4.7}$$

что и доказывает требуемый закон выборки. Если сеть выдаёт $s_\phi(x) = \log \sigma^2_\phi(x)$, используется $z = \mu_\phi(x) + \exp(s_\phi(x)/2) \odot \epsilon$. Дисперсия равна e^s, а стандартное отклонение — $e^{s/2}$. Вариант с полной ковариацией $\Sigma_\phi = A_\phi A_\phi^\mathsf{T}$ получается заменой $\sigma \odot \epsilon$ на $A_\phi \epsilon$; обычно A_ϕ выбирается треугольной матрицей с положительной диагональю.

4.4. Две оценки SGVB

Пусть $\epsilon^{(i,1)}, \dots, \epsilon^{(i,L)}$ независимы и имеют закон $p(\epsilon)$, а $z^{(i,l)} = g_\phi(\epsilon^{(i,l)}, x^{(i)})$. Подстановка выборочного среднего вместо ожидания (2.4) даёт общую оценку [1, формула (6)]:

$$\widetilde{\mathcal{L}}^A(\theta, \phi; x^{(i)}) = \frac{1}{L} \sum_{l=1}^{L} \left[\log p_\theta(x^{(i)}, z^{(i,l)}) - \log q_\phi(z^{(i,l)} \mid x^{(i)}) \right]. \tag{4.8}$$

Линейность ожидания и (4.4) показывают, что $\mathbb{E}_\epsilon \widetilde{\mathcal{L}}^A = \mathcal{L}$. Если KL к априорному закону вычисляется аналитически, формула (2.11) даёт оценку [1, формула (7)]:

$$\widetilde{\mathcal{L}}^B(\theta, \phi; x^{(i)}) = \frac{1}{L} \sum_{l=1}^{L} \log p_\theta(x^{(i)} \mid z^{(i,l)}) - D_{\mathrm{KL}}(q_\phi(z \mid x^{(i)}) \| p_\theta(z)). \tag{4.9}$$

Её ожидание также равно ELBO. При условиях (4.5) градиенты этих оценок несмещённы относительно градиентов ELBO. Ни $\widetilde{\mathcal{L}}^A$, ни $\widetilde{\mathcal{L}}^B$ при одной реализации шума не обязаны лежать ниже $\log p_\theta(x)$: нижней границей является их математическое ожидание.

Аналитический KL исключает шум оценивания этого члена и обычно полезен. Однако без дополнительных предположений нельзя утверждать универсальное уменьшение дисперсии всей суммы: у случайных слагаемых исходной оценки может быть ненулевая ковариация. В статье также используется формулировка о типичном, а не безусловном снижении дисперсии.

4.5. Мини-батчи и полный алгоритм

Пусть $i_1, \dots, i_M$ — независимые равномерные индексы из $\{1, \dots, N\}$, независимые от нового шума. По условному ожиданию и равномерности индексов

$$\begin{aligned} \mathbb{E}\left[\frac{N}{M} \sum_{m=1}^{M} \widetilde{\mathcal{L}}(\theta, \phi; x^{(i_m)}) \right] &= \frac{N}{M} \sum_{m=1}^{M} \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(\theta, \phi; x^{(i)}) \\ &= \sum_{i=1}^{N} \mathcal{L}(\theta, \phi; x^{(i)}). \end{aligned} \tag{4.10}$$

Это обоснование множителя N/M в формуле (8) статьи. Если оптимизируется средняя граница $N^{-1} \sum_i \mathcal{L}_i$, используется $1/M$. При MAP априорный член для глобальных параметров добавляется один раз, а не один раз на каждый объект.

Для пояснения роли L и M зафиксируем параметры. Пусть одно стохастическое слагаемое для объекта i имеет среднее $\mathcal{L}_i$ и дисперсию V_i. Среднее по L независимым выборкам имеет дисперсию V_i/L. По формуле полной дисперсии для случайного равномерного индекса I,

$$\mathrm{Var}\left(\frac{N}{M} \sum_{m=1}^{M} \widetilde{\mathcal{L}}_{i_m} \right) = \frac{N^2}{M} \left[\mathrm{Var}_I(\mathcal{L}_I) + \frac{1}{L} \mathbb{E}_I V_I \right]. \tag{4.11}$$

Здесь использованы независимость M слагаемых и правило $\mathrm{Var}(cY) = c^2 \mathrm{Var}(Y)$. Увеличение L уменьшает шум скрытой переменной, но не вариацию между объектами. Этим объясняется разумность малого L при достаточно большом батче; это не означает, что $L = 1$ всегда обеспечивает нужную точность. В экспериментах статьи использовались $M = 100$, $L = 1$ [1, алгоритм 1].

Один шаг AEVB состоит из выбора мини-батча, вычисления параметров q_ϕ, получения репараметризованных выборок z, вычисления декодерного логарифма правдоподобия и KL, после чего берётся градиент по обоим наборам параметров. Для минимизации в программном коде используется знак минус перед границей. Термин SGVB относится к оценивателю и его градиенту; AEVB — к алгоритму обучения модели с общим энкодером; VAE — к конкретной нейросетевой вероятностной модели.

5. Гауссовский VAE и функции потерь

5.1. Энкодер и декодер как параметризации распределений

В примере раздела 3 статьи выбирается фиксированное априорное распределение $p_\theta(z) = \mathcal{N}(0, I_J)$; индекс θ здесь не означает наличия обучаемых параметров в самом априорном законе. Энкодер задаётся как

$$q_\phi(z \mid x) = \mathcal{N}\big(z; \mu_\phi(x), \mathrm{diag}(e^{s_\phi(x)})\big)\,. \tag{5.1}$$

Это определение вариационного семейства, а не утверждение, что точное $p_\theta(z \mid x)$ нормально. Даже при нормальном априорном законе нелинейный декодер может порождать существенно ненормальное апостериорное распределение.

Однослойный MLP-энкодер ширины H можно определить формулами

$$h_\phi(x) = \tanh(Ax + a), \quad \mu_\phi(x) = B_\mu h_\phi(x) + b_\mu, \quad s_\phi(x) = B_s h_\phi(x) + b_s. \tag{5.2}$$

Здесь $A \in \mathbb{R}^{H\times D}$, $a \in \mathbb{R}^H$, $B_\mu, B_s \in \mathbb{R}^{J\times H}$, $b_\mu, b_s \in \mathbb{R}^J$, а ϕ объединяет эти матрицы и векторы. Гиперболический тангенс применяется покоординатно. После подстановки $x^{(i)}$ получаются $\mu^{(i)}$ и $s^{(i)}$ исходной статьи. Размеры объектов показывают, почему выход энкодера — два вектора длины J, а не одна точка в скрытом пространстве.

Для бернуллиевского декодера зададим

$$h_\theta(z) = \tanh(Cz + c), \qquad a_\theta(z) = Wh_\theta(z) + b, \qquad \rho_\theta(z) = \mathrm{sigmoid}(a_\theta(z)). \tag{5.3}$$

Здесь $C \in \mathbb{R}^{H\times J}$, $c \in \mathbb{R}^H$, $W \in \mathbb{R}^{D\times H}$, $b \in \mathbb{R}^D$, $\theta = \{C, c, W, b\}$, и $\mathrm{sigmoid}(t) = 1/(1 + e^{-t})$. Вектор a_θ содержит логиты, ρ_θ — вероятности. Это та же конструкция, что в приложении C.1 статьи, с переименованным выходным вектором y.

5.2. Полный вывод гауссовской KL

Опустим индекс наблюдения и аргумент x. Логарифмы нормальных плотностей имеют вид

$$\log q_\phi(z \mid x) = -\frac{J}{2}\log(2\pi) - \frac{1}{2}\sum_{j=1}^{J}\left[\log\sigma_j^2 + \frac{(z_j - \mu_j)^2}{\sigma_j^2}\right], \tag{5.4}$$

$$\log p(z) = -\frac{J}{2}\log(2\pi) - \frac{1}{2}\sum_{j=1}^{J} z_j^2. \tag{5.5}$$

Поскольку q имеет среднее μ и диагональные дисперсии σ_j^2, из определения дисперсии следуют

$$\mathbb{E}_q(z_j - \mu_j)^2 = \sigma_j^2, \qquad \mathbb{E}_q z_j^2 = \mathrm{Var}_q\, z_j + (\mathbb{E}_q z_j)^2 = \sigma_j^2 + \mu_j^2. \tag{5.6}$$

Берём ожидания (5.4)–(5.5) и подставляем (5.6):

$$\mathbb{E}_q \log q_\phi(z \mid x) = -\frac{J}{2}\log(2\pi) - \frac{1}{2}\sum_j(\log\sigma_j^2 + 1), \tag{5.7}$$

$$\mathbb{E}_q \log p(z) = -\frac{J}{2}\log(2\pi) - \frac{1}{2}\sum_j(\sigma_j^2 + \mu_j^2). \tag{5.8}$$

По определению KL из первой строки вычитаем вторую. Общие нормировочные константы сокращаются:

$$\boxed{D_{\mathrm{KL}}(q_\phi(z \mid x)\|p(z)) = \frac{1}{2}\sum_{j=1}^{J}\left(\mu_j^2 + \sigma_j^2 - 1 - \log\sigma_j^2\right).} \tag{5.9}$$

Это вычисление приложения B статьи. Подстановка $\sigma_j^2 = e^{s_j}$ даёт удобную для кода форму

$$D_{\mathrm{KL}} = \frac{1}{2}\sum_j(\mu_j^2 + e^{s_j} - 1 - s_j), \qquad \frac{\partial D_{\mathrm{KL}}}{\partial \mu_j} = \mu_j, \quad \frac{\partial D_{\mathrm{KL}}}{\partial s_j} = \frac{1}{2}(e^{s_j} - 1). \tag{5.10}$$

Последние два равенства получаются обычным дифференцированием первого. В частности, при $\mu = 0$, $s = 0$ KL равна нулю, как и должно быть при совпадении q с p.

Подставляя минус (5.9) в (4.9), получаем формулу (10) статьи:

$$\begin{aligned}\widetilde{\mathcal{L}}^B(\theta,\phi;x^{(i)}) = {}& \frac{1}{2}\sum_{j=1}^{J}\left[1 + \log(\sigma_j^{(i)})^2 - (\mu_j^{(i)})^2 - (\sigma_j^{(i)})^2\right] \\ & + \frac{1}{L}\sum_{l=1}^{L}\log p_\theta(x^{(i)} \mid z^{(i,l)}), \qquad z^{(i,l)} = \mu^{(i)} + \sigma^{(i)} \odot \epsilon^{(i,l)}.\end{aligned} \tag{5.11}$$

Здесь $\epsilon^{(i,l)} \sim \mathcal{N}(0, I_J)$ независимо. В реализации минимизируется отрицательная величина (5.11).

5.3. Бернуллиевский декодер и бинарная кросс-энтропия

Для бинарного наблюдения $x \in \{0,1\}^D$ предположим условную независимость координат при заданном z и зададим

$$p_\theta(x \mid z) = \prod_{d=1}^{D}\rho_{\theta,d}(z)^{x_d}[1 - \rho_{\theta,d}(z)]^{1-x_d}. \tag{5.12}$$

Это определение вероятностной модели. Логарифм произведения равен сумме, поэтому

$$\log p_\theta(x \mid z) = \sum_{d=1}^{D}\left[x_d \log\rho_{\theta,d}(z) + (1 - x_d)\log(1 - \rho_{\theta,d}(z))\right]. \tag{5.13}$$

Именно это формула (11) статьи. Для логита a имеем $\log\rho = a - \log(1+e^a)$ и $\log(1-\rho) = -\log(1+e^a)$. Подставляя эти два выражения в отрицание (5.13), получаем

$$-\log p_\theta(x \mid z) = \sum_{d=1}^{D}\left[\mathrm{softplus}(a_{\theta,d}(z)) - x_d a_{\theta,d}(z)\right], \qquad \mathrm{softplus}(t) := \log(1 + e^t). \tag{5.14}$$

В программной реализации эта сумма вычисляется устойчивой функцией бинарной кросс-энтропии от логитов. Не требуется сначала явно вычислять вероятности, а затем брать логарифмы чисел, близких к нулю.

Если исходные пиксели вещественны и лежат между нулём и единицей, подстановка их непосредственно в (5.13) не делает их наблюдениями бернуллиевской модели. Нужно либо явно задать бинаризацию, либо выбрать плотность для непрерывных интенсивностей. В блокноте моделируются бинарные величины $x_d = \mathbf{1}\{r_d \geq 8\}$, где исходные интенсивности r_d принадлежат $\{0, \dots, 16\}$.

5.4. Гауссовский декодер и квадратичная ошибка

Для $x \in \mathbb{R}^D$ определим декодер

$$p_\theta(x \mid z) = \mathcal{N}(x; m_\theta(z), \mathrm{diag}(\tau_\theta^2(z))), \tag{5.15}$$

где $m_\theta(z) \in \mathbb{R}^D$ — вектор средних, $\tau_{\theta,d}(z) > 0$ — стандартные отклонения наблюдений. Буква τ отделяет шум декодера от вариационных стандартных отклонений σ. Обе функции могут задаваться MLP, как в приложении C.2 статьи. Из логарифма нормальной плотности следует

$$-\log p_\theta(x \mid z) = \frac{1}{2}\sum_{d=1}^{D}\left[\log(2\pi) + \log\tau_{\theta,d}^2(z) + \frac{(x_d - m_{\theta,d}(z))^2}{\tau_{\theta,d}^2(z)}\right]. \tag{5.16}$$

Если все $\tau_{\theta,d}(z) = \tau > 0$ заранее фиксированы, то

$$-\log p_\theta(x \mid z) = \frac{D}{2}\log(2\pi\tau^2) + \frac{\|x - m_\theta(z)\|^2}{2\tau^2}. \tag{5.17}$$

Первый член не влияет на оптимальные параметры среднего, но нужен для численных значений логарифма плотности. Если дисперсия обучается, член $\log\tau^2$ зависит от параметров и отбрасывать его нельзя. Следовательно, «ошибка реконструкции» — не произвольно выбранная метрика, а отрицательный логарифм заданного декодерного закона.

5.5. Редукции в коде и вес KL

Для батча размера M при L выборках используется отрицательная средняя оценка

$$\mathcal{J}_M = \frac{1}{M}\sum_{m=1}^{M}\left[-\frac{1}{L}\sum_{l=1}^{L}\log p_\theta(x^{(i_m)} \mid z^{(i_m,l)}) + \frac{1}{2}\sum_{j=1}^{J}((\mu_j^{(i_m)})^2 + e^{s_j^{(i_m)}} - 1 - s_j^{(i_m)})\right]. \tag{5.18}$$

Сумма по координатам наблюдения уже содержится в $\log p_\theta(x \mid z)$. Сначала суммируются координаты d или j, затем усредняются выборки l и объекты. Если усреднить реконструкционный член по D, но оставить KL прежней, относительный вес KL изменится в D раз.

Для отдельного коэффициента β можно определить $\mathcal{L}_\beta = \mathbb{E}_q \log p_\theta(x \mid z) - \beta D_{\mathrm{KL}}(q\|p)$. Добавив и вычтя обычную KL, получаем

$$\mathcal{L}_\beta = \mathcal{L} - (\beta - 1)D_{\mathrm{KL}}(q\|p). \tag{5.19}$$

Лишь при $\beta = 1$ это исходная ELBO с тождеством (2.5). При $\beta \geq 1$ критерий всё ещё является нижней границей, поскольку из ELBO вычитается неотрицательная величина. При $\beta < 1$ общей гарантии нижней границы уже нет. В демонстрациях используется $\beta = 1$ на всём протяжении обучения.

5.6. Реконструкция, генерация и коллапс апостериорного распределения

Выдаваемый декодером вектор вероятностей или средних не равен случайному наблюдению. Для реконструкции часто рисуют $m_\theta(\mu_\phi(x))$ или $\rho_\theta(\mu_\phi(x))$. При нелинейном декодере это вообще говоря не совпадает с $\mathbb{E}_{q_\phi(z|x)} m_\theta(z)$ или $\mathbb{E}_q \rho_\theta(z)$. Для генерации новых независимых объектов используется априорное $z \sim p(z)$, а затем выборка $x \sim p_\theta(x \mid z)$; исходное наблюдение и энкодер для этой операции не нужны.

Полезно точно записать смысл среднего KL-штрафа. Пусть $p_{\text{emp}}(x)$ — эмпирическое распределение наблюдений и

$$q_{\text{agg}}(z) := \mathbb{E}_{p_{\text{emp}}(x)} q_\phi(z \mid x) = \frac{1}{N}\sum_{i=1}^{N} q_\phi(z \mid x^{(i)}). \tag{5.20}$$

Совместный закон $q(x,z) = p_{\text{emp}}(x)q_\phi(z \mid x)$ определяет взаимную информацию $I_q(X;Z) := \mathbb{E}_q \log[q_\phi(z \mid x)/q_{\text{agg}}(z)]$. Добавив и вычтя $\log q_{\text{agg}}(z)$ внутри среднего KL, получаем

$$\begin{aligned}\mathbb{E}_{p_{\text{emp}}(x)} D_{\mathrm{KL}}(q_\phi(z \mid x)\|p(z)) &= \mathbb{E}_q \log\frac{q_\phi(z \mid x)}{q_{\text{agg}}(z)} + \mathbb{E}_q \log\frac{q_{\text{agg}}(z)}{p(z)} \\ &= I_q(X;Z) + D_{\mathrm{KL}}(q_{\text{agg}}\|p).\end{aligned} \tag{5.21}$$

Во второй строке последний интегранд не зависит от x, поэтому его ожидание берётся по маргинальному q_{agg}. Формула показывает два эффекта KL: ограничение информации о наблюдении и приближение агрегированного распределения к априорному.

Если декодер фактически не зависит от z, то из (1.3) следует $p_\theta(z \mid x) = p(z)$. При выборе $q_\phi = p$ KL равна нулю, а скрытая переменная не несёт информации о x. Это точный предельный случай коллапса апостериорного распределения. Он не нарушает ELBO, но не даёт информативного скрытого представления. Нулевая KL, напротив, не является целью, которую следует безусловно навязывать полезному энкодеру.

6. Переход к классификации и регрессии

6.1. Соответствие двух постановок

Пусть теперь дана размеченная выборка

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N, \qquad x_i \in \mathbb{R}^n, \tag{6.1}$$

где n — размерность входа. В классификации $y_i \in \{1, \dots, K\}$ и K — число классов; в скалярной регрессии $y_i \in \mathbb{R}$. Индекс x_i здесь равнозначен $x^{(i)}$ статьи и не является номером координаты вектора. Для координат по-прежнему используются d или явно записанное $(x_i)_d$.

В исходном VAE переменная x обозначает *весь наблюдаемый объект*; выделенной целевой переменной нет. Из наличия энкодера $q_\phi(z \mid x)$ не возникает автоматически ни $p(y \mid x)$, ни классификационная функция потерь. Для перехода к (6.1) необходимо указать, что моделируется: распределение входов, совместное распределение пар или условное распределение цели.

Объект	Исходный VAE	Совместная модель	Условная модель
Наблюдение в ELBO	x	$\tilde{x} = (x, y)$	y при фиксированном x
Маргинальная цель	$\log p_\theta(x)$	$\log p_\theta(x, y)$	$\log p_\theta(y \mid x)$
Априорный закон z	$p_\theta(z)$	$p_\theta(z)$	$p_\theta(z \mid x)$
Энкодер обучения	$q_\phi(z \mid x)$	$q_\phi(z \mid x, y)$	$q_\phi(z \mid x, y)$
Закон интегрирования z для $y \mid x$	Не определён без новой модели	$p_\theta(z \mid x)$	$p_\theta(z \mid x)$, заданный как условный prior

Таблица 2: Роль наблюдения и скрытого распределения. В двух последних столбцах одинаковая запись $p_\theta(z \mid x)$ имеет разный статус: апостериорный закон по входу в совместной модели и явно параметризованный условный априорный закон в условной модели.

В основной статье обучение с учителем со скрытыми переменными упомянуто как направление дальнейшей работы [1, раздел 7], а не как уже проведённый классификационный или регрессионный эксперимент. Ниже приведено самостоятельное применение выведенного тождества. Условная конструкция связана с работой [2]; модель частично размеченных данных — с [3].

6.2. Первый вариант: признаки VAE и отдельный предиктор

Сначала можно обучить исходную модель $p_\theta(x, z)$ только по входам x_i. Затем фиксируются параметры энкодера и вводится новый предиктор

$$r_\psi(y \mid h_\phi(x)), \qquad h_\phi(x) \coloneqq \mu_\phi(x), \tag{6.2}$$

где ψ — новые параметры, а $h_\phi(x) \in \mathbb{R}^J$ — выбранный вектор признаков. Условное правдоподобие обучающей выборки при независимости целей есть произведение $\prod_i r_\psi(y_i \mid h_\phi(x_i))$. После логарифмирования его отрицание равно сумме отрицательных логарифмов этих вероятностей или плотностей.

Для классификации задаётся категориальное распределение. Его вероятности $r_{\psi,k}(h)$ неотрицательны и в сумме равны единице. Тогда минимизируется

$$\mathcal{J}_{\text{cls}}(\psi) = -\sum_{i=1}^{N} \log r_{\psi,y_i}(h_\phi(x_i)). \tag{6.3}$$

Это обычная категориальная кросс-энтропия, полученная из правдоподобия. Для регрессии модель $r_\psi(y \mid h) = \mathcal{N}(y; m_\psi(h), \tau^2)$ при фиксированном $\tau > 0$ даёт сумму квадратов ошибок с множителем $1/(2\tau^2)$ плюс константу, по тому же вычислению, что (5.17).

Можно определить и стохастический предиктор $r(y \mid x) := \int r_\psi(y \mid z) q_\phi(z \mid x)\,\mathrm{d}z$. Он нормирован, поскольку интеграл по y от каждого $r_\psi(y \mid z)$ равен единице. Но это *добавленная* условная модель, а не распределение $p_\theta(y \mid x)$, которое будто бы уже присутствовало в исходном VAE. Неразмеченная ELBO не гарантирует, что признаки сохранят всю информацию, нужную для конкретной цели y.

6.3. Второй вариант: совместная модель пары

Объявим наблюдением исходной вариационной схемы $\tilde{x} = (x, y)$ и определим

$$p_\theta(x, y, z) = p_\theta(z) p_\theta(x \mid z) p_\theta(y \mid x, z). \tag{6.4}$$

Последние два множителя — правило цепочки для $p_\theta(x, y \mid z)$. В отличие от замены на $p_\theta(x \mid z) p_\theta(y \mid z)$, здесь не навязывается дополнительная условная независимость $x \perp y \mid z$. При вещественном y наблюдение имеет $n + 1$ вещественных координат; при категориальном y используется смешанная мера: мера Лебега по x и считающая мера по y. Кодирование номера класса вещественным числом не делает его гауссовским наблюдением.

Для любого допустимого $q_\phi(z \mid x, y)$ формула (2.4) с $\tilde{x} = (x, y)$ даёт

$$\begin{aligned} \mathcal{L}_{\text{joint}}(\theta, \phi; x, y) &= \mathbb{E}_q \left[\log p_\theta(x, y, z) - \log q_\phi(z \mid x, y)\right] \\ &= \mathbb{E}_q \log p_\theta(x \mid z) + \mathbb{E}_q \log p_\theta(y \mid x, z) - D_{\text{KL}}(q_\phi(z \mid x, y) \| p_\theta(z)). \end{aligned} \tag{6.5}$$

Первое равенство — определение ELBO, второе — подстановка (6.4). Её разрыв до $\log p_\theta(x, y)$ равен $D_{\text{KL}}(q_\phi(z \mid x, y) \| p_\theta(z \mid x, y))$ по уже доказанному тождеству.

Для предсказания на новом входе цель неизвестна. Интегрируя y в (6.4), получаем $p_\theta(x, z) = p_\theta(z) p_\theta(x \mid z)$: условный закон $y \mid x, z$ нормирован. Поэтому

$$p_\theta(y \mid x) = \int p_\theta(y \mid x, z) p_\theta(z \mid x)\,\mathrm{d}z, \qquad p_\theta(z \mid x) \propto p_\theta(z) p_\theta(x \mid z). \tag{6.6}$$

В этом интеграле нельзя без обоснования заменить $p_\theta(z \mid x)$ на $p_\theta(z)$, а энкодер $q_\phi(z \mid x, y)$ нельзя вызвать с неизвестной истинной меткой. Нужно отдельно организовать вывод $z \mid x$, например обучить доступный по x энкодер, либо вычислять совместные вероятности для возможных классов. Можно также изначально выбрать для границы семейство $q_\phi(z \mid x)$, не использующее y: граница останется корректной, но её приближение к $p_\theta(z \mid x, y)$ будет более ограниченным.

6.4. Третий вариант: условный VAE

Когда требуется именно прогноз $y \mid x$, можно непосредственно определить условную модель

$$p_\theta(y, z \mid x) = p_\theta(z \mid x) p_\theta(y \mid x, z), \qquad p_\theta(y \mid x) = \int p_\theta(z \mid x) p_\theta(y \mid x, z)\,\mathrm{d}z. \tag{6.7}$$

Здесь x — наблюдаемый контекст, а $p_\theta(z \mid x)$ — *заданный условный априорный закон*. В частности, допустим выбор $p_\theta(z \mid x) = \mathcal{N}(0, I_J)$, не зависящий от x. Этот частный случай используется в блокноте. Моделировать распределение входов $p(x)$ для условного правдоподобия не требуется.

При обучении пара (x, y) полностью известна, поэтому вводится $q_\phi(z \mid x, y)$. Предположим $0 < p_\theta(y \mid x) < \infty$ и те же условия абсолютной непрерывности и интегрируемости, что в разделе 2. Формула Байеса для условной модели даёт

$$p_\theta(z \mid x, y) = \frac{p_\theta(z \mid x) p_\theta(y \mid x, z)}{p_\theta(y \mid x)}. \tag{6.8}$$

Подставим её в апостериорную KL и раскроем логарифм:

$$\begin{aligned} D_{\mathrm{KL}}(q_\phi(z \mid x, y) \| p_\theta(z \mid x, y)) = \mathbb{E}_q \left[\log q_\phi(z \mid x, y) - \log p_\theta(z \mid x) - \log p_\theta(y \mid x, z) \right] \\ + \log p_\theta(y \mid x). \end{aligned} \tag{6.9}$$

Нормировка q позволяет вынести последнее слагаемое. Перестановка членов даёт

$$\mathcal{L}_{\text{cond}}(\theta, \phi; x, y) := \mathbb{E}_{q_\phi(z \mid x, y)} \log p_\theta(y \mid x, z) - D_{\mathrm{KL}}(q_\phi(z \mid x, y) \| p_\theta(z \mid x)), \tag{6.10}$$

$$\log p_\theta(y \mid x) = \mathcal{L}_{\text{cond}}(\theta, \phi; x, y) + D_{\mathrm{KL}}(q_\phi(z \mid x, y) \| p_\theta(z \mid x, y)). \tag{6.11}$$

Следовательно, $\mathcal{L}_{\text{cond}}$ — нижняя граница условного логарифма правдоподобия. Если цели условно независимы по наблюдениям при заданных входах, критерий выборки равен сумме $\sum_i \mathcal{L}_{\text{cond}}(x_i, y_i)$.

Ни одного нового принципа вывода в (6.9) нет: это тот же расчёт, что (2.3), с фиксированным контекстом x. Меняется вероятностная задача и состав доступных переменных. Именно поэтому VAE-подход переносится и на классификацию, и на регрессию, но не путём произвольной замены слова «реконструкция» на «ошибка предсказания».

6.5. Условный гауссовский prior и вычисление его KL

Для общего диагонального варианта обозначим

$$q_\phi(z \mid x, y) = \mathcal{N}(\mu^q, \mathrm{diag}((\sigma^q)^2)), \qquad p_\theta(z \mid x) = \mathcal{N}(\mu^p, \mathrm{diag}((\sigma^p)^2)). \tag{6.12}$$

Здесь $\mu^q = \mu_\phi(x, y)$ и $\sigma^q = \sigma_\phi(x, y)$ — выходы энкодера, $\mu^p = \mu^p_\theta(x)$ и $\sigma^p = \sigma^p_\theta(x)$ — параметры условного prior; все стандартные отклонения положительны. Параметры этого prior относятся к θ, а не к ϕ.

По разложению квадрата вокруг среднего q,

$$\mathbb{E}_q (z_j - \mu_j^p)^2 = (\sigma_j^q)^2 + (\mu_j^q - \mu_j^p)^2. \tag{6.13}$$

Смешанный член равен нулю, поскольку $\mathbb{E}_q(z_j - \mu_j^q) = 0$. Подстановка (6.13) в логарифм нормальной плотности p, а затем вычитание из $\mathbb{E}_q \log q$ даёт

$$D_{\mathrm{KL}}(q \| p) = \frac{1}{2} \sum_{j=1}^{J} \left[\log \frac{(\sigma_j^p)^2}{(\sigma_j^q)^2} + \frac{(\sigma_j^q)^2 + (\mu_j^q - \mu_j^p)^2}{(\sigma_j^p)^2} - 1 \right]. \tag{6.14}$$

При $\mu^p = 0$, $\sigma^p = \mathbf{1}$ формула сводится к (5.9). Выборки при обучении имеют вид $z = \mu^q + \sigma^q \odot \epsilon$, а при предсказании — $z = \mu^p + \sigma^p \odot \epsilon$. В обоих случаях $\epsilon \sim \mathcal{N}(0, I_J)$, но распределения выборок принципиально различаются.

6.6. Классификация: категориальный декодер

Для K классов пусть сеть выдаёт логиты $a_\theta(x, z) \in \mathbb{R}^K$. Определим нормированные вероятности

$$\pi_{\theta,k}(x, z) = \frac{\exp a_{\theta,k}(x, z)}{\sum_{r=1}^{K} \exp a_{\theta,r}(x, z)}, \qquad p_\theta(y = k \mid x, z) = \pi_{\theta,k}(x, z). \tag{6.15}$$

Положительность и сумма единица следуют из определения. Для наблюдаемой метки y логарифм вероятности равен

$$\log p_\theta(y \mid x, z) = a_{\theta,y}(x, z) - \log \sum_{r=1}^{K} e^{a_{\theta,r}(x,z)}. \tag{6.16}$$

Следовательно, отрицательная условная ELBO есть ожидаемая категориальная кросс-энтропия плюс KL к условному prior. Для нормального $q_\phi(z \mid x, y)$ все шаги SGVB сохраняются. Наблюдаемая дискретная метка y не генерируется в процедуре вывода и не требует дифференцирования через выборку класса. В энкодер её можно передать вектором индикаторов длины K, у которого координата y равна единице, а остальные равны нулю.

Интегрируя категориальный закон по prior, получаем предсказательные вероятности

$$P_{\theta,k}(x) := p_\theta(y = k \mid x) = \mathbb{E}_{p_\theta(z|x)} \pi_{\theta,k}(x, z) \approx \frac{1}{S} \sum_{s=1}^{S} \pi_{\theta,k}(x, z^{(s)}), \tag{6.17}$$

где S — число независимых выборок prior при предсказании. Каждое слагаемое является вероятностным вектором, поэтому их среднее также нормировано. Усреднение логитов с последующим softmax вообще говоря даёт другой ответ, поскольку softmax нелинеен.

Если действие — предсказать класс k, а потеря равна единице при ошибке и нулю при совпадении, то условный риск равен $\sum_{r \neq k} P_{\theta,r}(x) = 1 - P_{\theta,k}(x)$. Его минимизация эквивалентна правилу

$$\widehat{y}(x) \in \arg \max_{1 \leq k \leq K} P_{\theta,k}(x). \tag{6.18}$$

При равенстве максимумов можно заранее задать правило разрешения неоднозначности.

Смесь категориальных законов остаётся категориальным законом: её параметры — средние вероятности в (6.17). Поэтому при достаточно выразительной зависимости декодера от x скрытая переменная для обычной классификации может быть избыточна. Если $p_\theta(y \mid x, z)$ не зависит от z и $q_\phi(z \mid x, y) = p_\theta(z \mid x)$, то KL равна нулю, а (6.10) совпадает с обычным условным логарифмом правдоподобия. Это объясняет, почему малый KL в классификационном эксперименте не обязательно указывает на ошибку.

6.7. Регрессия: условная смесь нормальных распределений

Для скалярной цели зададим

$$p_\theta(y \mid x, z) = \mathcal{N}(y; m_\theta(x, z), \tau_\theta^2(x, z)), \qquad \tau_\theta(x, z) > 0. \tag{6.19}$$

Из логарифма нормальной плотности, как в (5.16), следует

$$-\log p_\theta(y \mid x, z) = \frac{1}{2} \left[\log(2\pi) + \log \tau_\theta^2(x, z) + \frac{(y - m_\theta(x, z))^2}{\tau_\theta^2(x, z)} \right]. \tag{6.20}$$

После взятия ожидания по $q_\phi(z \mid x, y)$ и добавления KL получается отрицательная условная ELBO. При фиксированном τ изменяется только масштаб квадратичной ошибки; при обучаемом τ обязательно сохраняется логарифм дисперсии.

Предсказательная плотность представляет собой смесь

$$p_\theta(y \mid x) = \int \mathcal{N}(y; m_\theta(x, z), \tau_\theta^2(x, z)) p_\theta(z \mid x) \, \mathrm{d}z. \tag{6.21}$$

Она не обязана быть нормальной и может иметь несколько мод. Для её численной оценки можно усреднять плотности декодера по prior, а для получения случайных ответов — сначала выбирать $z \sim p_\theta(z \mid x)$, затем $y \sim p_\theta(y \mid x, z)$. Ни одна из этих операций не использует неизвестную тестовую цель в энкодере.

Пусть соответствующие вторые моменты конечны. Из условного нормального закона следуют $\mathbb{E}[y \mid x, z] = m_\theta(x, z)$ и $\mathbb{E}[y^2 \mid x, z] = \tau_\theta^2(x, z) + m_\theta^2(x, z)$. Последовательно интегрируя z, а затем вычитая квадрат среднего, получаем

$$\bar{m}_\theta(x) := \mathbb{E}[y \mid x] = \mathbb{E}_{p_\theta(z|x)} m_\theta(x, z), \tag{6.22}$$

$$\begin{aligned}\mathrm{Var}(y \mid x) &= \mathbb{E}_{p_\theta(z|x)} \tau_\theta^2(x, z) + \mathbb{E}_{p_\theta(z|x)} m_\theta^2(x, z) - \bar{m}_\theta^2(x) \\ &= \mathbb{E}_{p_\theta(z|x)} \tau_\theta^2(x, z) + \mathrm{Var}_{p_\theta(z|x)}\, m_\theta(x, z).\end{aligned} \tag{6.23}$$

Это закон полной дисперсии, здесь выведенный непосредственно из первых двух моментов.

Для любого точечного ответа $c \in \mathbb{R}$, добавляя и вычитая $\bar{m}_\theta(x)$ под квадратом и используя нулевое среднее центрированного остатка, имеем

$$\mathbb{E}[(y - c)^2 \mid x] = \mathrm{Var}(y \mid x) + (c - \bar{m}_\theta(x))^2. \tag{6.24}$$

Поэтому среднее (6.22) минимизирует квадратичный риск. Но хороший средний ответ не описывает форму многомодальной плотности. Для получения интервала с заданной предсказательной вероятностью нужно вычислять квантили смеси, а не автоматически использовать среднее ± 1.96 стандартного отклонения.

Оба члена (6.23) относятся к одному фиксированному θ. Вариативность по z не равна по определению неопределённости о параметрах модели. Для последней нужен дополнительный закон параметров, например полностью байесовский вариант приложения A. В стандартном AEVB случайность скрытого кода сама по себе не превращает точечную оценку весов в байесовское распределение весов.

7. Частично размеченные данные: дополнительная модель

Этот раздел относится к расширению [3], а не к экспериментам статьи [1]. Пусть часть меток известна, а часть отсутствует. В модели M2 определяется совместный закон

$$p_\theta(x, y, z) = p(y)p(z)p_\theta(x \mid y, z), \qquad p(y = k) = \pi_k, \quad \pi_k > 0, \quad \sum_k \pi_k = 1. \tag{7.1}$$

Здесь $y \in \{1, \dots, K\}$, $z \in \mathbb{R}^J$, а $p(z)$ обычно выбирается $\mathcal{N}(0, I_J)$. Априорная независимость y и z — часть этой модели. Она отличается от направленной условной постановки (6.7).

Для размеченной пары (x, y) выбирается $q_\phi(z \mid x, y)$. Подстановка (7.1) в общий ELBO даёт

$$\mathcal{L}_l(x, y) = \log p(y) + \mathbb{E}_{q_\phi(z|x,y)} \log p_\theta(x \mid y, z) - D_{\mathrm{KL}}(q_\phi(z \mid x, y) \| p(z)). \tag{7.2}$$

Индекс l означает labeled; параметры θ, ϕ в аргументах для краткости опущены. Эта граница относится к $\log p_\theta(x, y)$.

Для неразмеченного x обе величины y и z скрыты. Зададим нормированное приближение

$$q_\phi(y, z \mid x) = q_\phi(y \mid x) q_\phi(z \mid x, y). \tag{7.3}$$

У категориального $q_\phi(y \mid x)$ вероятности суммируются в единицу, а условное $q_\phi(z \mid x, y)$ интегрируется в единицу для каждого класса. Поэтому (7.3) действительно нормировано. Раскрыв логарифм обоих множителей внутри ELBO, получаем

$$\begin{aligned}\mathcal{L}_u(x) &= \sum_{k=1}^K q_\phi(k \mid x)\, \mathbb{E}_{q_\phi(z|x,k)} \left[\log p_\theta(x, k, z) - \log q_\phi(z \mid x, k) - \log q_\phi(k \mid x)\right] \\ &= \sum_{k=1}^K q_\phi(k \mid x) \mathcal{L}_l(x, k) - \sum_{k=1}^K q_\phi(k \mid x) \log q_\phi(k \mid x) \\ &= \sum_{k=1}^K q_\phi(k \mid x) \mathcal{L}_l(x, k) + H(q_\phi(y \mid x)),\end{aligned} \tag{7.4}$$

где $H(r) := -\sum_k r_k \log r_k$ — энтропия дискретного распределения, а u означает unlabeled. Для умеренного K сумма по классам вычисляется точно. Тогда репараметризуются только непрерывные z, и градиент через случайную дискретную метку не требуется.

Пусть $\mathcal{D}_l$ и $\mathcal{D}_u$ — размеченная и неразмеченная части. Сумма $\sum_{(x,y)\in\mathcal{D}_l} \mathcal{L}_l(x,y) + \sum_{x\in\mathcal{D}_u} \mathcal{L}_u(x)$ является границей соответствующего наблюдаемого логарифма правдоподобия. Но отдельный классификационный выход $q_\phi(y \mid x)$ не присутствует в (7.2); наличие общих слоёв этого алгебраического факта не меняет. Для прямого обучения классификатора по известным меткам в [3] добавляется взвешенный член классификации. При соглашении о *максимизации* это имеет вид

$$\sum_{(x,y)\in\mathcal{D}_l} \mathcal{L}_l(x,y) + \sum_{x\in\mathcal{D}_u} \mathcal{L}_u(x) + \alpha \sum_{(x,y)\in\mathcal{D}_l} \log q_\phi(y \mid x), \qquad \alpha \geq 0. \tag{7.5}$$

Здесь α относится к записи через сумму; в статье используется также нормировка через эмпирическое ожидание, и численное значение коэффициента при смене нормировки изменяется. В фиксированной модели (7.1) дополнительное слагаемое — отдельный критерий, а не ещё один член простого раскрытия той же ELBO. Работа [3] обсуждает и другую, расширенную вероятностную интерпретацию. Знаки (7.2)–(7.5) сохранены в соглашении исходной статьи VAE: границы максимизируются; в статье о частичном обучении некоторые обозначения введены как минимизируемые отрицательные границы.

8. Точные примеры для проверки вычислений

8.1. Скалярная линейно-гауссовская модель

Рассмотрим $z \sim \mathcal{N}(0,1)$ и $x \mid z \sim \mathcal{N}(az+b, \tau^2)$, где $a, b \in \mathbb{R}$, $\tau > 0$ — фиксированные параметры. Здесь $D = J = 1$. Для данного наблюдения обозначим $d = x - b$, $T = a^2 + \tau^2$, $v = \tau^2/T$ и $m = ad/T$. Совместная плотность равна

$$p_\theta(x,z) = \frac{1}{2\pi\tau} \exp\left\{ -\frac{1}{2}\left[z^2 + \frac{(d-az)^2}{\tau^2} \right] \right\}. \tag{8.1}$$

Она получается умножением двух нормальных плотностей. Раскрытие квадрата и приведение коэффициентов дают

$$\begin{aligned} z^2 + \frac{(d-az)^2}{\tau^2} &= \frac{T}{\tau^2} z^2 - \frac{2ad}{\tau^2} z + \frac{d^2}{\tau^2} \\ &= \frac{(z-m)^2}{v} + \frac{d^2}{T}. \end{aligned} \tag{8.2}$$

Для проверки свободного члена достаточно подставить $m^2/v = a^2 d^2/(\tau^2 T)$: сумма $m^2/v + d^2/T$ равна d^2/τ^2.

В (8.1) после подстановки (8.2) интеграл по z равен $\sqrt{2\pi v}$. Поэтому

$$p_\theta(x) = \frac{\sqrt{2\pi v}}{2\pi\tau} \exp\left(-\frac{d^2}{2T} \right) = \frac{1}{\sqrt{2\pi T}} \exp\left(-\frac{d^2}{2T} \right), \tag{8.3}$$

$$p_\theta(z \mid x) = \mathcal{N}(z; m, v). \tag{8.4}$$

Вторая строка получается делением совместной плотности на первую. Таким образом, точные апостериорные параметры и точная маргинальная плотность известны.

Для $q(z) = \mathcal{N}(\mu, e^s)$ по определению среднего и дисперсии

$$\mathbb{E}_q (d - az)^2 = (d - a\mu)^2 + a^2 e^s. \tag{8.5}$$

Действительно, $d - az = (d - a\mu) - a(z - \mu)$, смешанный член в квадрате имеет нулевое ожидание. Подстановка (8.5) и одномерной (5.9) в (2.11) даёт

$$\mathcal{L}(\mu, s) = -\frac{1}{2}\left[\log(2\pi\tau^2) + \frac{(d-a\mu)^2 + a^2 e^s}{\tau^2} \right] - \frac{1}{2}(\mu^2 + e^s - 1 - s). \tag{8.6}$$

Дифференцируя по μ и s, получаем

$$\partial_\mu \mathcal{L} = \frac{a(d - a\mu)}{\tau^2} - \mu, \qquad \partial_s \mathcal{L} = \frac{1}{2}\left[1 - e^s\left(1 + \frac{a^2}{\tau^2}\right)\right]. \tag{8.7}$$

Приравнивание производных к нулю даёт $\mu = m$ и $e^s = v$. Вторые производные равны $-(1 + a^2/\tau^2) < 0$ и $-e^s(1 + a^2/\tau^2)/2 < 0$; смешанная производная нулевая. Поэтому найденная стационарная точка — единственный глобальный максимум. В нём q совпадает с (8.4), и ELBO равна логарифму (8.3).

Для произвольных μ, s общий гауссовский расчёт (6.14) в одной координате даёт

$$D_{\mathrm{KL}}(q \| p_\theta(z \mid x)) = \frac{1}{2}\left[\frac{e^s + (\mu - m)^2}{v} - 1 + \log v - s\right]. \tag{8.8}$$

Поэтому равенство $\log p_\theta(x) - \mathcal{L}(\mu, s) = D_{\mathrm{KL}}(q \| p_\theta(z \mid x))$ можно проверить без Монте-Карло. В блокноте оно сравнивается также с численным интегралом совместной плотности.

8.2. Ненулевой разрыв диагонального семейства

Пусть нормированная целевая плотность $p_* = \mathcal{N}(0, \Sigma)$ имеет ковариацию

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \qquad |\rho| < 1. \tag{8.9}$$

Здесь ρ — коэффициент корреляции; p_* можно рассматривать как заданное точное апостериорное распределение. Приближаем его $q = \mathcal{N}(\mu, V)$, где $V = \operatorname{diag}(v_1, v_2)$, $v_1, v_2 > 0$. Обозначим точность $\Lambda = \Sigma^{-1}$. Из логарифма многомерной нормальной плотности

$$\log p_*(z) = -\log(2\pi) - \frac{1}{2}\log\det\Sigma - \frac{1}{2} z^{\mathsf{T}} \Lambda z. \tag{8.10}$$

Поскольку $\mathbb{E}_q z z^{\mathsf{T}} = V + \mu\mu^{\mathsf{T}}$ и $z^{\mathsf{T}}\Lambda z = \operatorname{tr}(\Lambda z z^{\mathsf{T}})$, линейность следа и ожидания даёт

$$\mathbb{E}_q z^{\mathsf{T}}\Lambda z = \operatorname{tr}(\Lambda V) + \mu^{\mathsf{T}}\Lambda\mu. \tag{8.11}$$

Для q ожидаемая собственная квадратичная форма равна размерности, то есть 2. Вычитая ожидаемые логарифмы q и p_*, получаем

$$D_{\mathrm{KL}}(q \| p_*) = \frac{1}{2}\left[\operatorname{tr}(\Lambda V) + \mu^{\mathsf{T}}\Lambda\mu - 2 + \log\frac{\det\Sigma}{\det V}\right]. \tag{8.12}$$

Матрица Λ положительно определена, поэтому квадратичный член минимален при $\mu = 0$. Для каждой дисперсии зависимая от неё часть равна $(\Lambda_{jj} v_j - \log v_j)/2$. Её производная $(\Lambda_{jj} - 1/v_j)/2$ обращается в нуль при $v_j = 1/\Lambda_{jj}$, а вторая производная $1/(2v_j^2) > 0$ доказывает минимум.

В данном случае $\det\Sigma = 1 - \rho^2$ и $\Lambda = (1-\rho^2)^{-1}\begin{pmatrix} 1 & -\rho \\ -\rho & 1 \end{pmatrix}$. Отсюда оптимальное $V = (1-\rho^2) I_2$, $\operatorname{tr}(\Lambda V) = 2$ и

$$\min_{\mu, V \text{ диаг.}} D_{\mathrm{KL}}(q \| p_*) = -\frac{1}{2}\log(1 - \rho^2). \tag{8.13}$$

При $\rho = 0.9$ эта величина положительна, а вариационные дисперсии равны 0.19 вместо единицы. Пример показывает ограничение семейства, не проблему оптимизатора. Он не доказывает, что всякое вариационное приближение обязано недооценивать дисперсию при любой модели.

8.3. Дисперсия скор-градиента и pathwise-градиента

Возьмём $z = \mu + \sigma\epsilon$, $\epsilon \sim \mathcal{N}(0,1)$, где $\sigma > 0$ фиксировано, и функцию $f(z) = (z-c)^2$ для фиксированного $c \in \mathbb{R}$. Обозначим $\delta = \mu - c$. Тогда

$$F(\mu) = \mathbb{E} f(z) = \delta^2 + \sigma^2, \qquad F'(\mu) = 2\delta. \tag{8.14}$$

Это следует из $\mathbb{E}\epsilon = 0$, $\mathbb{E}\epsilon^2 = 1$. Дифференцирование самой композиции даёт $G_{\text{path}} = 2(\delta + \sigma\epsilon)$. Скор нормальной плотности по μ равен $(z-\mu)/\sigma^2 = \epsilon/\sigma$, поэтому

$$G_{\text{score}} = (\delta + \sigma\epsilon)^2 \frac{\epsilon}{\sigma} = \frac{\delta^2}{\sigma}\epsilon + 2\delta\epsilon^2 + \sigma\epsilon^3. \tag{8.15}$$

Оба ожидания равны 2δ.

Для вычисления дисперсий достаточно моментов ϵ до шестого порядка. Пусть $\varphi(t)$ — плотность стандартного нормального закона. Так как $\varphi'(t) = -t\varphi(t)$, интегрирование по частям даёт для целого $r \geq 2$

$$\mathbb{E}\epsilon^r = -\int t^{r-1}\varphi'(t)\,\mathrm{d}t = (r-1)\int t^{r-2}\varphi(t)\,\mathrm{d}t = (r-1)\mathbb{E}\epsilon^{r-2}. \tag{8.16}$$

Граничный член нулевой благодаря гауссовскому убыванию плотности. Нечётные моменты равны нулю по симметрии; чётные моменты нужного порядка равны $1, 3, 15$.

Для pathwise-оценки непосредственно $\operatorname{Var} G_{\text{path}} = 4\sigma^2$. Если в (8.15) обозначить коэффициенты при $\epsilon, \epsilon^2, \epsilon^3$ через $A = \delta^2/\sigma$, $B = 2\delta$, $C = \sigma$, то $\mathbb{E}G_{\text{score}}^2 = A^2 + 3(B^2 + 2AC) + 15C^2$. Вычитая $(2\delta)^2$, получаем

$$\operatorname{Var} G_{\text{score}} = \frac{\delta^4}{\sigma^2} + 14\delta^2 + 15\sigma^2, \qquad \operatorname{Var} G_{\text{path}} = 4\sigma^2. \tag{8.17}$$

Для baseline $b = F(\mu) = \delta^2 + \sigma^2$ скор-оценка равна $G_b = 2\delta\epsilon^2 + \sigma(\epsilon^3 - \epsilon)$. Её центрированная чётная часть $2\delta(\epsilon^2 - 1)$ некоррелирована с нечётной частью. Поэтому

$$\operatorname{Var} G_b = 4\delta^2(3-1) + \sigma^2(15 - 2\cdot 3 + 1) = 8\delta^2 + 10\sigma^2. \tag{8.18}$$

Среднее по L независимым реализациям имеет дисперсию, равную соответствующей величине, делённой на L. Блокнот сравнивает эти формулы с повторными выборочными оценками. Вывод о превосходстве pathwise по дисперсии в данном примере не заменяет анализа другой функции или другого семейства распределений.

9. Вычислительная часть семинара

9.1. Протокол и связь с исходной работой

Блокнот `variational_inference_elbo_vae.ipynb` содержит математические пояснения, непосредственно за которыми следуют вычисления. Все показанные в нём численные результаты получены исполнением ячеек. Отдельные синтетические примеры выбраны так, чтобы иллюстрируемое утверждение можно было проверить независимо от обучения нейронной сети.

В статье [1, раздел 5] генеративные модели обучались на MNIST и Frey Face; авторы сравнивали AEVB с wake-sleep, а в отдельном эксперименте — с Monte Carlo EM. Использовались Adagrad, $M = 100$, $L = 1$ и MAP-критерий с априорным распределением параметров. В приложении A визуализировались скрытые пространства. Эти результаты принадлежат статье и не подменяются результатами приведённого ниже блокнота.

Для локальной демонстрации используются UCI digits, поставляемые вместе со scikit-learn: 1797 изображений 8×8, исходные целочисленные интенсивности от 0 до 16 [4]. После пороговой бинаризации моделируется $D = 64$ бинарных координаты. Это другой набор данных, не уменьшенная

Эксперимент	Раздел блокнота	Обучение	Валидация	Тест
Бинарные цифры	4–6	1077	360	360
Две дуги, $K = 2$	7	1800	600	600
Двухмодальная регрессия	8	3000	1000	1000

Таблица 3: Число наблюдений в непересекающихся частях данных. Контрольные аналитические эксперименты в разделах 1–3 блокнота не используют эти выборки.

версия MNIST. Разделение на обучение, валидацию и тест фиксировано и стратифицировано по классу; использование классов для составления разбиения не означает использования меток в целевой функции VAE.

Основное начальное зерно генератора равно 1729; дополнительные зерна явно указаны в ячейках. VAE имеет по одному скрытому tanh-слою ширины 128 в энкодере и декодере, скрытые размерности $J = 2$ и $J = 8$. Условные модели имеют по два tanh-слоя ширины 64, $J = 1$. Оптимизатор — Adam с шагом 10^{-3}, без дополнительного штрафа на веса и без изменения коэффициента KL. Для VAE выполняется 260 эпох, для условной классификации — 130, для регрессии — 220. Эти настройки являются протоколом демонстрации, а не настройками оригинальных экспериментов статьи.

Обучающий мини-батч выбирается равномерно с возвращением, поэтому формула (4.10) применима условно на каждом шаге. Одна эпоха означает $\lceil N/M \rceil$ таких шагов, а не обязательное посещение каждого объекта. Для VAE $M = 100$, для условных моделей $M = 128$; во всех обучающих границах $L = 1$. Состояние модели выбирается по валидационному критерию, вычисленному с фиксированным шумом и $L = 16$. Тестовая ELBO оценивается новым шумом при $L = 128$.

При `TRAIN=True` блокнот обучает модели и сохраняет состояния. При `TRAIN=False` он загружает их из каталога `checkpoints/`. Наборы данных либо поставляются с библиотекой, либо генерируются в коде, поэтому скачивание данных не требуется. Результаты сохранены также в `results.json`; версии библиотек указаны в начале блокнота и в файле `requirements.txt`.

9.2. Проверки до обучения сети

В скалярном эксперименте заданы $a = 1.4$, $b = -0.2$, $\tau = 0.7$, $x = 1.1$. Код вычисляет (8.3)–(8.8), сравнивает аналитическую маргинальную плотность с численным интегралом и проверяет тождество ELBO на наборе случайных (μ, s). На рисунке 1 показана поверхность границы: максимум совпадает с точным апостериорным распределением. В этом опыте не используются ни стохастические градиенты, ни амортизация.

В следующем опыте точная цель — коррелированное нормальное распределение (8.9) с $\rho = 0.9$. Сравниваются контуры одинакового расстояния Махаланобиса у этой цели и у оптимального диагонального приближения. Ненулевой минимум (8.13) показывает, что даже идеальная оптимизация ограниченного семейства не закрывает разрыв до точного апостериорного распределения.

В градиентном опыте заданы $\mu = 0.4$, $\sigma = 0.7$, $c = 2$. Для каждого $L \in \{1, 4, 16, 64, 256\}$ повторяется 12000 независимых оценок среднего градиента. Сравниваются теоретические дисперсии (8.17)–(8.18) и наблюдаемый разброс. Кроме того, производная композиции проверяется центральными конечными разностями при *одном и том же* шуме с обеих сторон. Библиотечные `sample()` и `rsample()` сравниваются по сохранению связи с параметрами [5].

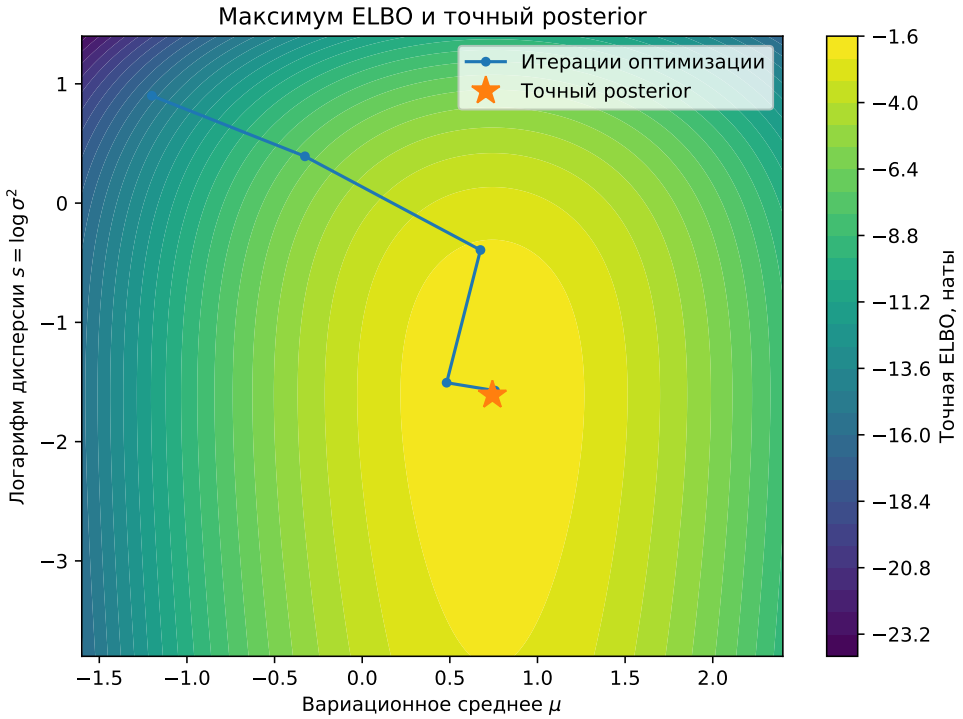


Рис. 1: ELBO как функция среднего μ и логарифма дисперсии s в точной одномерной модели. Отмечены итерации оптимизации и точное апостериорное решение. Цветовая шкала показывает наты на наблюдение.

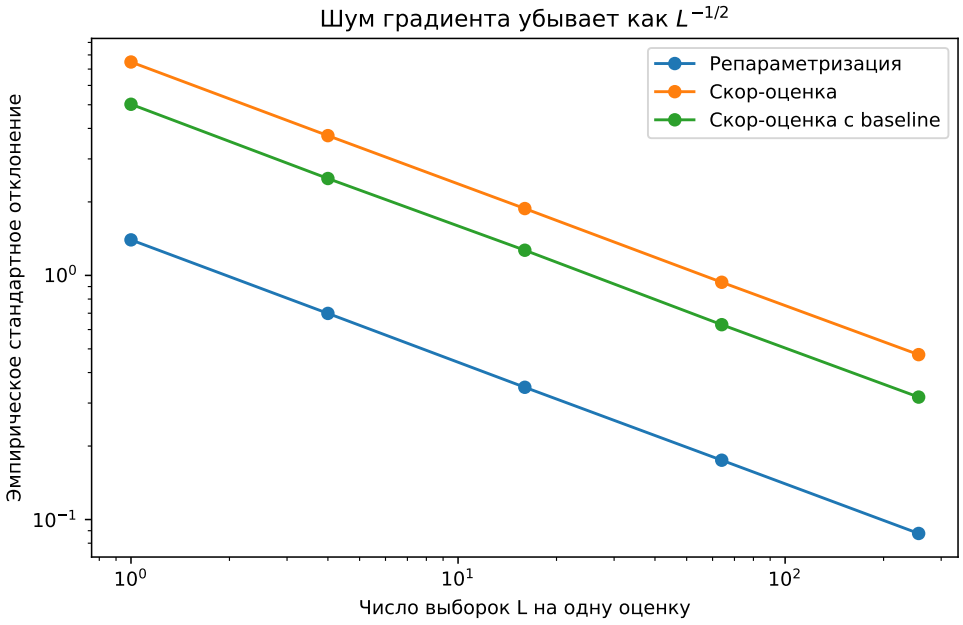


Рис. 2: Стандартное отклонение трёх оценок градиента в зависимости от L. Убывание порядка $L^{-1/2}$ следует из независимого усреднения; различие вертикальных уровней объясняется выведенными дисперсиями одновыборочных оценок.

9.3. VAE на бинарных цифрах

Обучение использует ровно (5.18): отрицательный бернуллиевский логарифм правдоподобия, суммированный по 64 координатам, плюс аналитическая KL, суммированная по J координатам. Метки цифр не входят ни в энкодер, ни в декодер, ни в валидационную границу. Визуализация меток после обучения и отдельное обучение классификационной головы представляют собой другие операции.

J	$-\widehat{\mathcal{L}}$	Реконстр. NLL	KL	Ст. ошибка
2	20.302	17.567	2.734	0.256
8	18.285	12.223	6.062	0.196

Таблица 4: Тестовые оценки VAE на бинарных UCI digits, наты на изображение. Реконструкционный член оценён при $L = 128$, KL вычислена аналитически. Стандартная ошибка рассчитана по разбросу 360 объектных оценок; она не описывает вариацию между независимыми запусками обучения.

При данном разбиении модель с $J = 8$ имеет более высокую оценку ELBO, чем модель с $J = 2$. Это сравнение конкретных обученных состояний, а не утверждение о монотонности качества по размерности скрытого пространства.

На кривых обучения сравниваются критерии в одинаковых единицах — натах на изображение. Для отображения обучающей кривой фиксированное состояние сети в конце эпохи оценивается на подвыборке из 512 обучающих объектов. Поэтому эта кривая не смешивает потери от разных состояний весов внутри одной эпохи. Тестовые числа в таблице 4 относятся к выбранному по валидации состоянию, а не обязательно к последней эпохе.

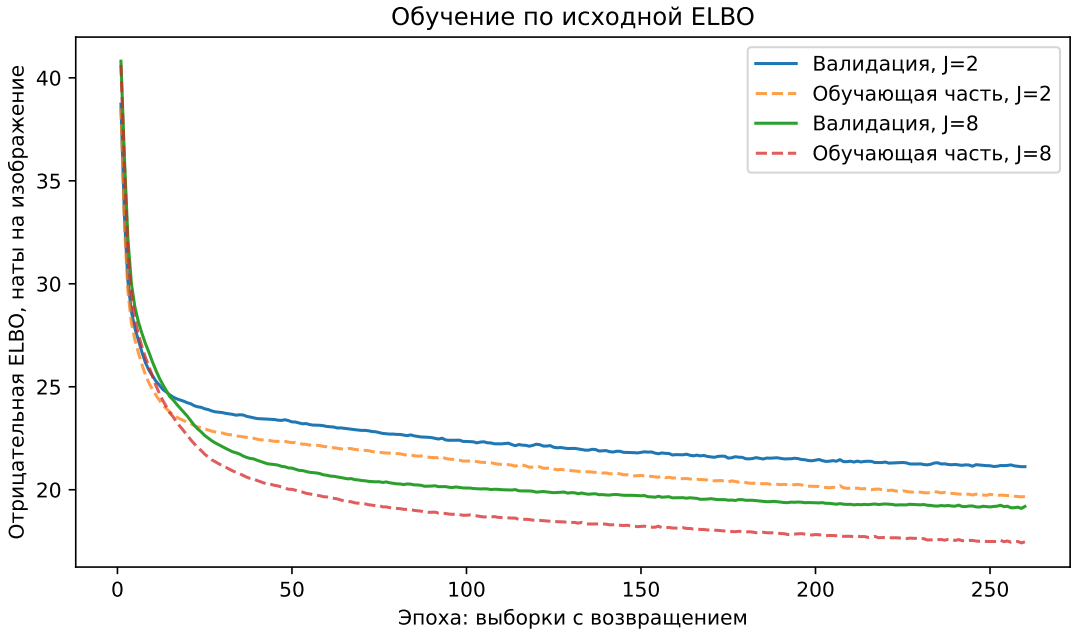


Рис. 3: Отрицательная средняя ELBO для $J = 2$ и $J = 8$. Пунктирные кривые вычислены на фиксированной обучающей подвыборке, сплошные — на валидации. Числа не являются точными отрицательными логарифмами маргинального правдоподобия.

В блокноте отдельно показаны реконструкции, апостериорные средние кодов, условные средние декодера и настоящие бинарные выборки. Для реконструкций выбирается первый тестовый объект каждой цифры в фиксированном порядке, а не наиболее удачно восстановленный объект. Сравниваются наблюдение, декодер в точке $\mu_\phi(x)$ и приближение ожидаемого декодерного среднего по 256 выборкам $q_\phi(z \mid x)$.

Для карты двумерного декодера берётся равномерная сетка $u_j \in [0.03, 0.97]$ и применяется $z_j = \Phi^{-1}(u_j)$, где Φ — функция распределения $\mathcal{N}(0,1)$. В одномерном случае $\Phi(z)$ равномерна при нормальном z, поэтому такая сетка соответствует равномерному шагу по накопленной априорной вероятности. Это способ построения карты из приложения A статьи [1]. На рисунке 4 показаны условные средние изображений; это не случайные бинарные реализации.

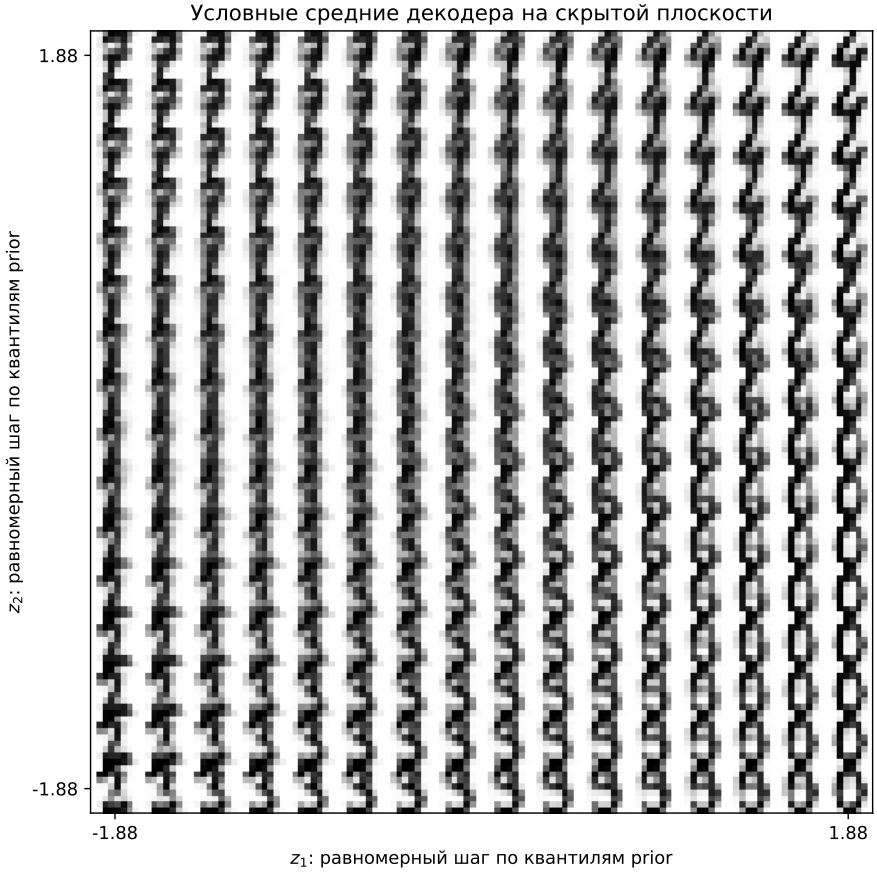


Рис. 4: Средние бернуллиевского декодера на сетке априорных квантилей, $J = 2$. Каждая плитка имеет размер 8×8. Карта описывает конкретную обученную модель UCI digits, а не изображения из статьи.

9.4. Логарифм правдоподобия и importance sampling

Для плотности-предложения $q_\phi(z \mid x)$, покрывающей носитель $p_\theta(x, z)$, определим вес $w(z) = p_\theta(x, z)/q_\phi(z \mid x)$. По сокращению q_ϕ внутри интеграла

$$\mathbb{E}_q w(z) = p_\theta(x), \qquad \mathbb{E}_q \log w(z) = \mathcal{L}(\theta, \phi; x). \tag{9.1}$$

Первое равенство требует условия покрытия носителя, обсуждавшегося в (2.8); второе — определение ELBO. Для S независимых выборок предложение даёт

$$\hat{p}_S(x) = \frac{1}{S}\sum_{s=1}^{S} w(z^{(s)}), \qquad \log \hat{p}_S(x) = \operatorname{logsumexp}_{s=1}^{S}(\log w(z^{(s)})) - \log S, \tag{9.2}$$

где $\operatorname{logsumexp}(a_1, \dots, a_S) := \log \sum_s e^{a_s}$ вычисляется устойчиво после вычитания максимального аргумента. Плотность $\hat{p}_S$ несмещённа, а её логарифм вообще говоря смещён. По Йенсену $\mathbb{E} \log \hat{p}_S \le \log p_\theta(x)$, но отдельная реализация не обязана быть нижней границей.

Для одного и того же набора логарифмов весов вогнутость логарифма даёт также

$$\log\left(\frac{1}{S}\sum_s w_s\right) \ge \frac{1}{S}\sum_s \log w_s.$$

В блокноте это неравенство проверяется напрямую. Нормированные веса $\bar{w}_s = w_s / \sum_r w_r$ определяют диагностическую величину

$$\mathrm{ESS} := \frac{1}{\sum_s \bar{w}_s^2} = \frac{(\sum_s w_s)^2}{\sum_s w_s^2}. \tag{9.3}$$

Второе равенство получается подстановкой нормировки. При равных весах ESS равна S, при доминировании одного веса близка к единице. Это мера концентрации весов, а не доказанная погрешность оценки.

Вычисление проводится на первых 128 тестовых объектах с $S = 256$ и $J = 8$. Данный простой importance sampler — дополнительная демонстрация связи ожидания весов с ожиданием их логарифмов. Он *не воспроизводит* оцениватель через MCMC из приложения D исходной статьи.

9.5. Классификация: два различных эксперимента

Первый опыт использует замороженные средние энкодера на цифрах и отдельную мультиномиальную логистическую регрессию. Стандартизация признаков оценивается только на обучении, затем применяется к тесту. Параметр регуляризации логистической регрессии фиксирован заранее. В качестве самостоятельного ориентира обучается такая же классификационная модель на исходных бинарных пикселях. Поскольку размерности входов различны, это не сравнение моделей одинаковой ёмкости. Его назначение — показать, что хорошая генеративная граница сама по себе не равна хорошему классификационному представлению.

Второй опыт обучает *условный VAE* на двух зашумлённых дугах в $\mathbb{R}^2$. Генератор `make_moons` использует параметр шума 0.23. Классы обозначаются как $1, 2$, координаты стандартизуются статистиками только обучающей части. Энкодер получает (x, y), декодер — (x, z), а prior фиксирован и равен $\mathcal{N}(0, 1)$. Сравнение с детерминированным двухслойным классификатором выполняется на той же тестовой части. Предсказательные вероятности VAE усредняются по $S = 256$ новым выборкам prior. Поверхность на рисунке 5 использует $S = 64$ для каждой точки сетки.

Признаки логистической регрессии	Доля верных	NLL
Среднее энкодера, $J = 2$	0.628	1.274
Среднее энкодера, $J = 8$	0.856	0.470
Исходные бинарные пиксели, $D = 64$	0.897	0.297

Таблица 5: Замороженные признаки на цифрах: отдельная логистическая регрессия, тестовая доля верных ответов и отрицательный логарифм предсказательной вероятности, наты на объект. Размерности входа различны, поэтому это не сравнение моделей с одинаковым объёмом информации.

Модель на двух дугах	Доля верных	Предсказательная NLL
Условный VAE	0.942	0.148
Детерминированный классификатор	0.942	0.152

Таблица 6: Условная классификация на тесте. Вероятности VAE усредняются по 256 выборкам из априорного распределения; истинный класс не подаётся в предсказательный алгоритм.

Средняя тестовая KL условного классификатора равна 0.000155 нат на объект. При таком малом значении энкодер почти совпадает с априорным распределением в среднем по тесту. Условная ELBO даёт отрицательную оценку границы 0.148934; предсказательная NLL в таблице 6 оценивается другим интегралом. Доля верных ответов в данном запуске совпала у двух моделей; преимуществ условного VAE по точности этот опыт не показывает.

Малый классификационный KL согласуется с выводом раздела 6.6: выразительный декодер может решать эту задачу, почти не используя z. Незначительная разность тестовых логарифмических потерь

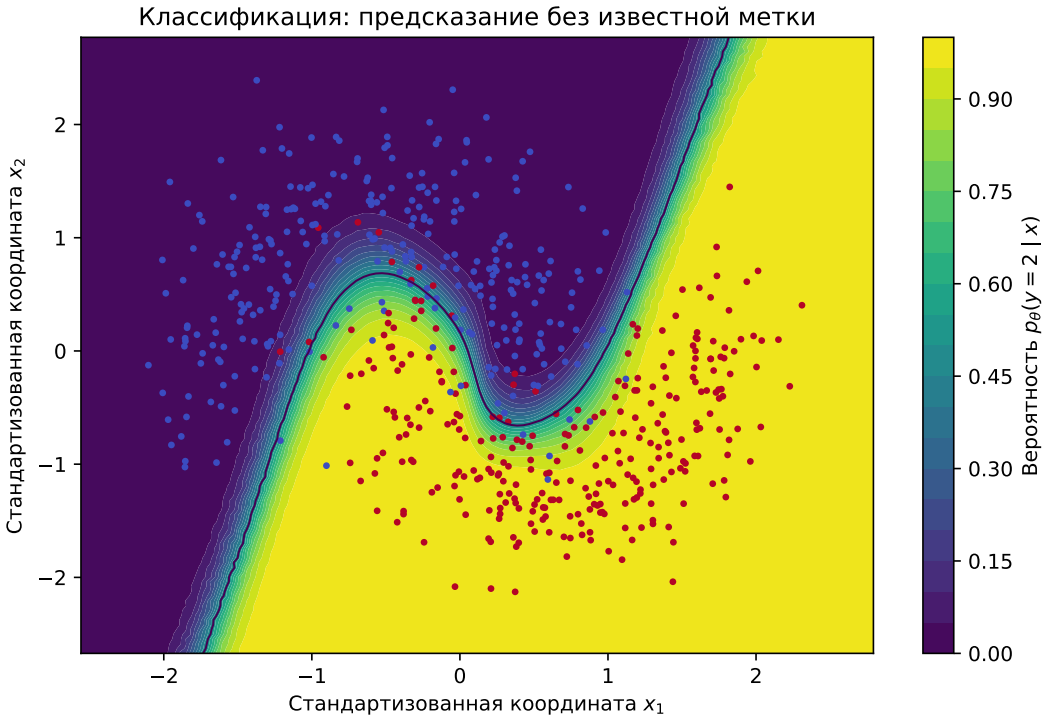


Рис. 5: Предсказательная вероятность второго класса у условного VAE. Нанесены тестовые наблюдения и линия вероятности $1/2$. При построении поверхности ни одна истинная метка не подаётся в энкодер: интегрируется априорное распределение скрытой переменной.

двух моделей в одном запуске не доказывает систематического преимущества одной из них. Здесь не проводились повторные запуски и статистическая проверка превосходства.

9.6. Регрессия с двумя возможными ответами

В синтетическом опыте независимо генерируются $x \sim \mathrm{Uniform}[-2, 2]$, знак $s_* \in \{-1, +1\}$ с вероятностями $1/2$ и шум $\eta \sim \mathcal{N}(0, 1)$. Определим

$$a(x) = 0.8 + 0.35\cos(\pi x), \quad \tau_* = 0.12, \qquad y = s_* a(x) + \tau_* \eta. \tag{9.4}$$

Индекс $*$ отличает величины генератора данных от обучаемых параметров; s_* здесь является знаком и не имеет отношения к логарифму вариационной дисперсии. Условно на знаке y нормально распределена, а усреднение двух равновероятных знаков даёт точную плотность

$$p_*(y \mid x) = \tfrac{1}{2}\mathcal{N}(y; a(x), \tau_*^2) + \tfrac{1}{2}\mathcal{N}(y; -a(x), \tau_*^2). \tag{9.5}$$

Из симметрии $\mathbb{E}_*[y \mid x] = 0$; по вторым моментам $\mathrm{Var}_*(y \mid x) = a(x)^2 + \tau_*^2$. Сам знак не передаётся сетям.

Условный VAE имеет одномерный нормальный prior и гауссовский декодер с заранее фиксированным $\tau = \tau_*$. В качестве ориентира используется один условный нормальный закон с обучаемыми средним и стандартным отклонением. Для положительности последнего в коде задано $\mathrm{softplus}(r_\psi(x)) + 0.03$, где r_ψ — второй скалярный выход сети. Этот ориентир может описывать зависимость дисперсии от x, но не две отдельные моды плотности.

Для одномерного z предсказательная плотность VAE вычисляется детерминированной квадратурой по prior. Пусть φ — стандартная нормальная плотность, $A = 8$, а t_s, w_s — узлы и веса квадратуры Гаусса–Лежандра на $[-1, 1]$. Сначала ограничиваем интеграл в (6.21) на $[-A, A]$, затем подставляем $z = At$ и получаем приближение

$$p_\theta(y \mid x) \approx \sum_{s=1}^{S} \bar{w}_s \mathcal{N}(y; m_\theta(x, At_s), \tau^2), \qquad \bar{w}_s = \frac{A w_s \varphi(At_s)}{\sum_r A w_r \varphi(At_r)}. \tag{9.6}$$

Веса нормированы, поэтому правая часть является плотностью смеси. Проверяется также близость ненормированной суммы весов к единице. При фиксированном τ каждая нормальная плотность ограничена сверху $1/(\tau\sqrt{2\pi})$. Поэтому отброшенный ненормированный хвост исходного интеграла не превосходит

$$\int_{|z|>A} \varphi(z)\mathcal{N}(y; m_\theta(x, z), \tau^2)\,\mathrm{d}z \le \frac{2\Phi(-A)}{\tau\sqrt{2\pi}}. \tag{9.7}$$

Для выбранных A и τ эта величина меньше $5 \cdot 10^{-15}$. Погрешность конечной квадратуры — отдельный вопрос. В блокноте сравниваются $S = 1024$ и $S = 2048$; такое сравнение диагностирует чувствительность чисел, но не заменяет доказанной оценки квадратурной погрешности.

Модель регрессии	Предсказательная NLL	RMSE среднего
Условный VAE, интеграл по prior	0.3015	0.8478
Одно условное нормальное распределение	1.1581	0.8503
Известное распределение генератора	-0.0086	0.8477

Таблица 7: Тестовая регрессия. NLL выражена в натах на наблюдение и относится к плотности, поэтому допускает отрицательные значения. RMSE вычислена для предсказательного среднего. Строка известного генератора не является обученной моделью.

Условная отрицательная ELBO равна 0.6246, её реконструкционный вклад -0.6147 и KL 1.2393. Они суммируются в отрицательную ELBO, но по отдельности не являются предсказательной NLL. При переходе от 1024 к 2048 узлам квадратуры среднее абсолютное изменение объектных логарифмов плотности составляет $7.52 \cdot 10^{-8}$, максимальное — $1.87 \cdot 10^{-6}$ нат. Это проверка сходимости для данного расчёта, не универсальная оценка ошибки квадратуры.

По ошибке среднего модели близки, поскольку истинное условное среднее равно нулю. По оценке плотности условный VAE заметно лучше одного нормального распределения, но хуже известной

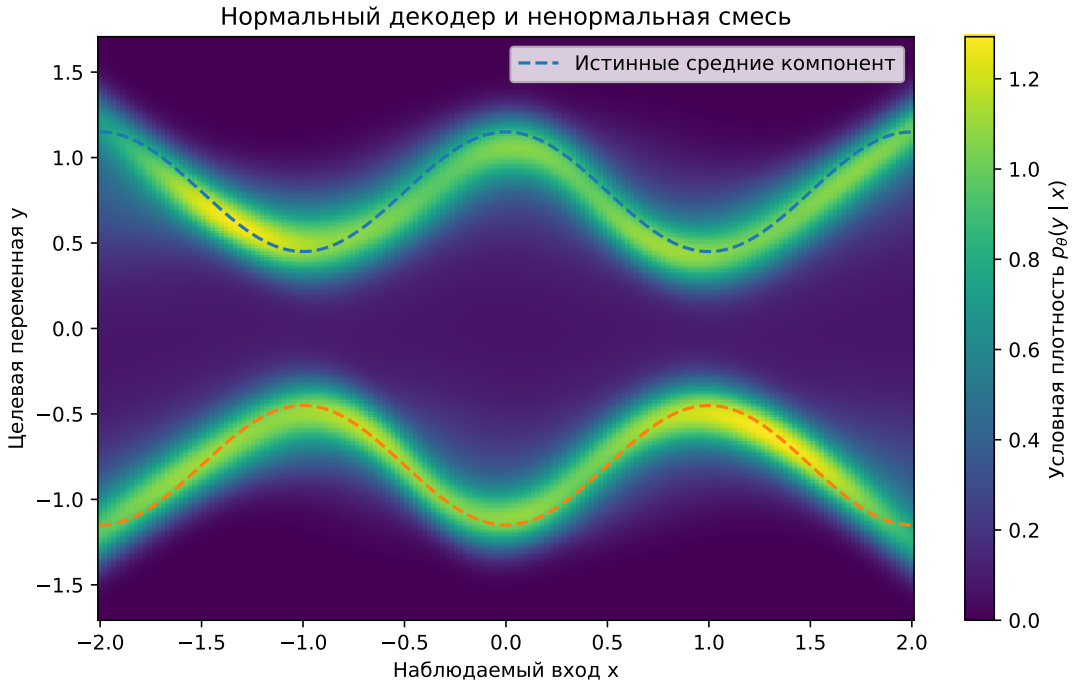


Рис. 6: Условная плотность VAE после интегрирования по prior. Пунктиром показаны два истинных условных средних компоненты $\pm a(x)$. Нормальность каждого декодерного закона при фиксированном z не препятствует многомодальности результата интегрирования.

смеси. Таким образом, улучшение модели условного распределения не обязано проявляться в RMSE среднего.

Среднеквадратическая ошибка оценивает только качество условного среднего. В данном симметричном примере среднее находится между модами, и близкие RMSE не означают близких предсказательных плотностей. Отрицательный логарифм плотности, в отличие от RMSE, различает эти ситуации. Отрицательное значение средней NLL истинной непрерывной модели допустимо: это плотность, а не вероятность отдельного исхода. Обученная модель не совпала с известной плотностью генератора; это также видно по ненулевому расхождению логарифмических потерь.

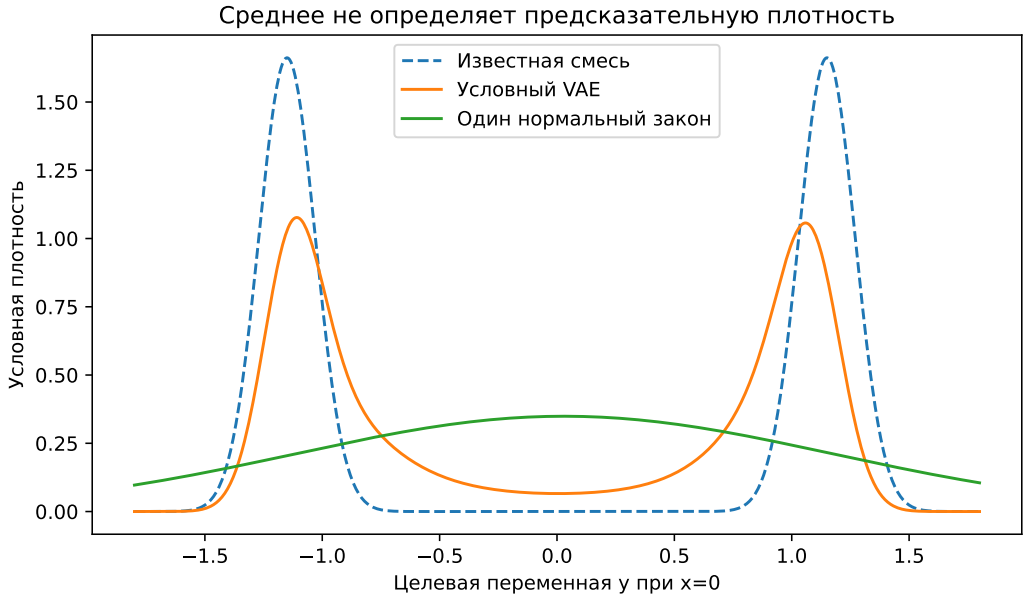


Рис. 7: Сечение условной плотности при $x = 0$. Сравниваются известная двухкомпонентная смесь, условный VAE и один условный нормальный закон. У этих распределений могут быть близкие средние при существенно разной форме плотности.

9.7. Что именно проверено

Аналитические проверки охватывают нормировку маргинальной плотности в точной модели, тождество ELBO, аналитическую KL и её производные, репараметризованный градиент с фиксированным шумом и разложение (7.4) для конечного набора классов. В нейросетевых опытах проверяются конечность потерь, корректность размерностей и нормировка предсказательных вероятностей. Все кодовые ячейки блокнота исполнены последовательно; ошибки исполнения не подавляются.

Эти проверки не доказывают глобальной оптимальности нейросетевого обучения, статистической значимости различий между моделями или корректности доверительных интервалов, которых в опытах не строилось. Оценка стандартной ошибки среднего по тестовым наблюдениям в блокноте отражает разброс между объектами и не является чистой оценкой Монте-Карло-ошибки. Между разными версиями библиотек и вычислительными платформами не предполагается побитового совпадения результатов.

A. Вариационный вывод для глобальных параметров

В основном тексте θ оптимизируется как неизвестный, но фиксированный вектор. Для полностью байесовской постановки, рассмотренной в приложении F статьи [1], задаётся prior $p_\alpha(\theta)$, где α — фиксированные гиперпараметры. Полный совместный закон имеет вид

$$p_\alpha(X, Z, \theta) = p_\alpha(\theta) \prod_{i=1}^{N} p_\theta(z^{(i)}) p_\theta(x^{(i)} \mid z^{(i)}), \qquad Z = (z^{(1)}, \dots, z^{(N)}). \tag{A.1}$$

Возьмём факторизованное приближение

$$q_\phi(\theta, Z \mid X) = q_\phi(\theta) \prod_{i=1}^{N} q_\phi(z^{(i)} \mid x^{(i)}). \tag{A.2}$$

Как и в приложении статьи, общий символ ϕ здесь включает параметры обоих видов факторов; это не означает, что веса этих факторов обязаны совпадать. Факторизация, не учитывающая условную зависимость локальных $z^{(i)}$ от θ внутри q, является ограничением выбранного семейства.

Применим к наблюдению X тождество ELBO, считая скрытыми сразу (θ, Z). Получим

$$\log p_\alpha(X) = \mathcal{L}_{\text{full}}(\phi; X) + D_{\text{KL}}(q_\phi(\theta, Z \mid X) \| p_\alpha(\theta, Z \mid X)). \tag{A.3}$$

Чтобы вычислить границу, берём ожидание логарифма отношения (A.1) и (A.2). Логарифм произведения раскладывается в сумму. Члены, зависящие только от θ, образуют минус глобальную KL; оставшиеся интегрируются по локальным факторам:

$$\begin{aligned}\mathcal{L}_{\text{full}}(\phi; X) = &-D_{\text{KL}}(q_\phi(\theta) \| p_\alpha(\theta)) \\ &+ \sum_{i=1}^{N} \mathbb{E}_{q_\phi(\theta)} \mathbb{E}_{q_\phi(z \mid x^{(i)})} \left[\log p_\theta(x^{(i)} \mid z) + \log p_\theta(z) - \log q_\phi(z \mid x^{(i)})\right].\end{aligned} \tag{A.4}$$

При репараметризации $\theta = h_\phi(\zeta)$ с новым параметрически независимым шумом ζ и $z = g_\phi(\epsilon, x)$ к обоим ожиданиям применяется тот же механизм (4.5). В мини-батчевой оценке множитель N/M относится только к сумме локальных вкладов; глобальная KL остаётся один раз. Таким образом, случайные веса в полностью байесовской модели появляются из отдельного вариационного распределения, а не из наличия случайного скрытого кода в обычном VAE.

Для условной предсказательной модели соответствующая байесовская плотность дополнительно усредняется по апостериорным параметрам:

$$p(y \mid x, \mathcal{D}) = \int p_\theta(y \mid x) p(\theta \mid \mathcal{D}) \, \mathrm{d}\theta. \tag{A.5}$$

Равенство следует из формулы полной вероятности при условной независимости нового ответа и обучающих данных по заданным x, θ. В вариационной реализации $p(\theta \mid \mathcal{D})$ заменяется выбранным приближением. Этот дополнительный уровень неопределённости в вычислительных опытах не использовался.

B. Порядок изложения у доски

Основную линию удобно строить от одной модели, не меняя значение её параметров по ходу вывода. Для каждого блока ниже указаны формулы, которые достаточно сохранить на доске до перехода к следующему блоку. Разделы о частично размеченных данных и глобальных параметрах можно обсуждать отдельно: они не требуются для понимания исходного AEVB.

Блок	Содержание у доски	Переход к вычислениям
1	$z \to x$, факторизация (1.1), интеграл (1.2), posterior (1.3). Определить θ, ϕ, локальный z и размерности.	Точный скалярный пример, раздел 1 блокнота.
2	KL, её неотрицательность, вывод (2.5), затем (2.11). Отделить две разные KL.	Поверхность ELBO и незакрываемый диагональным семейством разрыв, разделы 1–2.
3	Параметризованный закон под ожиданием; скор-формула (4.1); репараметризация (4.3) и правило цепочки (4.5).	Дисперсия градиента и проверка конечными разностями, раздел 3.
4	Гауссовский q, вывод (5.9), бинарный или нормальный декодер, оценка (5.11), множитель N/M.	Обучение, реконструкция и генерация — три разные операции, разделы 4–5.
5	$\mathcal{D} = \{(x_i, y_i)\}$; различить признаки, совместную и условную модели. Повторить вывод условной ELBO (6.9).	Отдельная голова на признаках и условный классификатор, разделы 6–7.
6	Обучение использует $q(z \mid x, y)$; предсказание — prior условной модели. Категориальная вероятность (6.17); среднее и дисперсия регрессии (6.22)–(6.23).	Двухмодальная регрессия и сравнение средней ошибки с плотностью, раздел 8.

Общий вывод не сводится к формуле «реконструкция плюс регуляризатор». Сначала задаётся нормированная вероятностная модель; затем из KL выводится её нижняя граница; после этого выбираются вариационное семейство, оцениватель и способ оптимизации. При смене задачи на классификацию или регрессию сохраняется этот порядок, но явно меняется наблюдаемая и условная часть модели.

Соответствие формулам основной статьи

В [1]	В конспекте	Содержание
(1), (2)	(2.5), (2.4)	Тождество ELBO и определение границы
(3)	(2.11)	Декодерный член минус KL к prior
(4), (5)	(4.3), (4.4)	Репараметризация и перенос ожидания
(6), (7)	(4.8), (4.9)	Две оценки SGVB
(8)	(4.10)	Мини-батчевая оценка
(9), (10)	(5.1), (5.11)	Гауссовский энкодер и целевая функция VAE
(11), (12)	(5.3)–(5.15)	Бернуллиевский и гауссовский MLP
Приложение B	(5.4)–(5.9)	Аналитическая гауссовская KL
Приложение F	Приложение A	Вариационный вывод параметров

Список литературы

[1] Kingma D. P., Welling M. *Auto-Encoding Variational Bayes*. arXiv:1312.6114. Использована предоставленная версия v11 от 10 декабря 2022 г.; первая версия размещена в 2013 г. Основные ссылки в тексте относятся к нумерации формул этой версии.
`https://arxiv.org/abs/1312.6114`

[2] Sohn K., Lee H., Yan X. *Learning Structured Output Representation using Deep Conditional Generative Models*. Advances in Neural Information Processing Systems 28, 2015. Раздел 4: условная генеративная модель и вариационное обучение.
Страница статьи в электронном сборнике NeurIPS 2015.

[3] Kingma D. P., Rezende D. J., Mohamed S., Welling M. *Semi-Supervised Learning with Deep Generative Models*. Advances in Neural Information Processing Systems 27, 2014. arXiv:1406.5298. Разделы 2–3: модели M1/M2 и критерии для размеченных и неразмеченных наблюдений.
`https://arxiv.org/abs/1406.5298`

[4] Scikit-learn. *sklearn.datasets.load_digits*. Документация набора UCI optical-recognition digits, поставляемого с библиотекой.
`https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html`

[5] PyTorch 2.10. *Probability distributions — torch.distributions*. Разделы о pathwise derivative, `rsample()` и `kl_divergence`.
`https://docs.pytorch.org/docs/2.10/distributions.html`